

## ECG 782 · DETECTION & ESTIMATION THEORY

---

**覆盖范围:** Kay, *Fundamentals of Statistical Signal Processing, Vol. I: Estimation Theory*

第 2 章 (MVU 估计) ~ 3.6 节 (参数变换)

**整理:** Chang Wang · **课程:** ECG 782 · **整理日期:** 2026-09-14

---

## 0. 全景地图：这几节在讲一条什么样的逻辑链

---

先把主线拎出来，后面所有细节都挂在这条链上：

怎么衡量一个估计量的好坏？ →  $mse = var + bias^2$  (2.6)  
↓ 直接最小化 mse 做不到（最优解依赖未知的  $\theta$ ）  
先强制无偏，再最小化方差 → MVU 估计量  
↓ MVU 存在吗？找得到吗？  
先问：无偏估计量最好能做到多好？ → CRLB  $var(\hat{\theta}) \geq 1/I(\theta)$  (3.6)  
↓  $I(\theta)$  怎么算？  
Fisher 信息 = 对数似然的平均曲率 →  $I(\theta) = -E[\partial^2 \ln p / \partial \theta^2]$   
↓ 界什么时候够得着？够得着时估计量是谁？  
可达条件（分解 score） →  $\partial \ln p / \partial \theta = I(\theta)(g(x) - \theta)$  (3.7)  
↓ 具体到"WGN 中的信号"这一大类模型  
通用公式 →  $var(\hat{\theta}) \geq \sigma^2 / \Sigma(\partial s / \partial \theta)^2$  (3.14)  
↓ 我关心的不是  $\theta$  而是  $g(\theta)$  怎么办？  
参数变换 →  $var(\alpha) \geq (\partial g / \partial \theta)^2 / I(\theta)$  (3.16)

一句话总结这几节：在动手设计算法之前，先在纸上算出"理论上最好能多准"，并且顺便看看那个最优估计量会不会自己掉出来。

---

## 1. 前置知识：从 MSE 到 MVU（第 2 章）

---

### 1.1 无偏 $\neq$ 好

无偏只保证"平均而言能命中真值"，不保证单次估计准。但无偏性在合并多个估计时至关重要。

### 1.2 平均 $n$ 个估计量：方差为什么是 $var(\theta_i)/n$

设  $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n \hat{\theta}_i$ ，两个假设各用在一步：

#### 第一步（用"互不相关"）

方差的两条基本性质：

- 常数提出要平方： $var(aX) = a^2 var(X)$ ，这里  $a = 1/n$ ，提出来是  $1/n^2$  而非  $1/n$
- 和的方差： $var(\sum_i \hat{\theta}_i) = \sum_i var(\hat{\theta}_i) + 2 \sum_{i < j} cov(\hat{\theta}_i, \hat{\theta}_j)$

**uncorrelated** 让所有协方差为零，交叉项整块消失：

$$var(\hat{\theta}) = \frac{1}{n^2} \sum_{i=1}^n var(\hat{\theta}_i)$$

⚠ 若各估计相关（例如来自同一批数据、共用同一噪声源），交叉项不为零，结论失效。极端情况：所有  $\hat{\theta}_i$  完全相同时，平均后方差一点也没降。

## 第二步（用"同方差"）

$\text{var}(\hat{\theta}_i) \equiv \sigma^2$  对所有  $i$  成立，于是求和是  $n$  个相同的数相加：

$$\text{var}(\hat{\theta}) = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n} = \frac{\text{var}(\hat{\theta}_1)}{n}$$

✳ 这里的  $\hat{\theta}_1$  没有任何特殊性，只是"随便拿一个当代表"来指代那个公共的  $\sigma^2$ 。写成  $\text{var}(\hat{\theta}_1)/n$  完全等价。

**直觉：**  $1/n^2$  与  $n$  项相加，一个平方、一个线性，净剩  $1/n$ ；标准差按  $1/\sqrt{n}$  下降。随机误差每次方向不同，相加时互相抵消（**非相干叠加**）。

**而偏差不会被抵消：** 若  $E(\hat{\theta}_i) = \theta + b$ ，则  $E(\hat{\theta}) = \theta + b$ 。偏差每次朝同一方向偏，是**相干叠加**： $n$  个  $b$  加起来是  $nb$ ，除以  $n$  又变回  $b$ 。

**核心结论：** 平均（或增加数据）能压方差，压不掉偏差。

## 1.3 图 2.2 怎么读

| 视觉现象              | 含义                                 | (a) 无偏 | (b) 有偏         |
|-------------------|------------------------------------|--------|----------------|
| 峰变高变窄（纵向）         | 方差 $\sigma^2/n$ 减小；密度积分恒为 1，变窄必然变高 | ✓ 有    | ✓ 有            |
| 峰偏离 $\theta$ （横向） | 偏差 $b$                             | ✗ 无    | ✓ 有，且不随 $n$ 缩小 |

- (a)：越来越准地锁定真值
- (b)：越来越**自信地锁定一个错值**—— $n$  增大反而使你对偏离真值的结果更加确信，情况更糟

## 1.4 MSE 分解： $\text{mse} = \text{var} + \text{bias}^2$ （式 2.6）

**配凑技巧：** 在括号里同时加减  $E(\hat{\theta})$ ：

$$\hat{\theta} - \theta = \underbrace{(\hat{\theta} - E(\hat{\theta}))}_A + \underbrace{(E(\hat{\theta}) - \theta)}_B$$

两部分性质完全不同：

- $A$  是**随机量**（围绕自身均值的抖动）， $E[A] = 0$
- $B$  是**确定常数**（ $E(\hat{\theta})$  和  $\theta$  都是固定数值），即偏差  $b(\theta)$

展开：

$$E[(A+B)^2] = \underbrace{E[A^2]}_{=\text{var}(\hat{\theta})} + \underbrace{2E[AB]}_{=2B \cdot E[A]=0} + \underbrace{E[B^2]}_{=b^2(\theta)}$$

交叉项为零的关键： $B$  是常数可提到期望外，而  $E[A] = 0$ 。

$$\text{mse}(\hat{\theta}) = \text{var}(\hat{\theta}) + b^2(\theta)$$

几何上等价于勾股定理：零均值随机分量  $A$  与常数分量  $B$  在  $L^2$  空间中正交，所以是平方相加、无交叉项。

1.5 为什么转向 MVU

$b(\theta)$  依赖未知的  $\theta$ ，所以直接最小化 mse 通常做不到（最优估计量会依赖你正在找的那个量）。因此教材转而：先强制  $b = 0$ （限定无偏），再最小化方差  $\rightarrow$  MVU 估计量。

1.6 图 2.5 怎么读

- 虚线是 CRLB，是  $\theta$  的函数（不同真值处难度不同），所有实线（各无偏估计量的方差）都在其上方
- $\hat{\theta}_2$  与  $\hat{\theta}_3$  相交  $\Rightarrow$  各有擅长区间，谁也不是一致最优。这是为什么 MVU 要求在每一个  $\theta$  上都最小 ("for each value of  $\theta$ ")
- $\hat{\theta}_1$  处处最低但没贴到虚线：下界达不到  $\neq$  MVU 不存在。此时 CRLB 这条路走不通，需改用 RBLS 定理（第 5 章）

2. 似然函数：定义与计算

2.1 一个函数，两种读法

似然函数和 PDF 是同一个函数  $p(\mathbf{x}; \theta)$ ，只是"把谁当变量"反过来了。

|      | 固定什么                   | 变量              | 问的问题                           |
|------|------------------------|-----------------|--------------------------------|
| PDF  | 参数 $\theta$            | 数据 $\mathbf{x}$ | 参数是 $\theta$ 时，各种数据出现的可能性分布？   |
| 似然函数 | 数据 $\mathbf{x}$ （已观测到） | 参数 $\theta$     | 我手上这组数据，在各候选 $\theta$ 下有多"像话"？ |

估计问题里数据已知、 $\theta$  未知，所以要反过来看。似然函数本质上是给每个候选  $\theta$  打分。

2.2 计算三步

1. 写出数据的 PDF（由信号+噪声模型决定）
2. 把实际观测到的数字代进去
3. 剩下的、只含  $\theta$  的表达式就是  $L(\theta)$

2.3 例子

离散（最直观）：抛 10 次得 7 正， $L(p) = \binom{10}{7} p^7 (1-p)^3$ 。  $L(0.5) = 0.117$ ,  $L(0.7) = 0.267$ ,  $L(0.2) = 0.0008 \Rightarrow p = 0.7$  最能解释数据，即 MLE。

连续（Example 3.1）： $x[0] = A + w[0]$ ,  $w[0] \sim \mathcal{N}(0, \sigma^2)$ ，代入观测值  $x[0] = 3$ ：

$$L(A) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{1}{2\sigma^2}(3-A)^2\right]$$

这就是图 3.1 画的曲线——横轴是  $A$ ，不是  $x$ 。

2.4 多样本与对数似然

独立时联合 PDF 连乘，取对数变连加：

$$\ln p(\mathbf{x}; A) = -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2$$

高斯情形下这是  $A$  的二次函数（开口向下的抛物线），求导一次即可解出峰值。

2.5 三个常见误区

| ✗ 错误理解                                               | ✓ 正确理解                                                                    |
|------------------------------------------------------|---------------------------------------------------------------------------|
| 似乎是 $\theta$ 的概率                                     | $\int L(\theta) d\theta \neq 1$ ，连续情形是密度值可 $>1$ 。只有相对大小有意义，常数因子可随便扔       |
| $p(\mathbf{x}; \theta)$ 与 $p(\mathbf{x}  \theta)$ 一样 | 分号表示 $\theta$ 是确定但未知的常数（经典/频率派）；竖线是贝叶斯的条件概率， $\theta$ 也是随机变量并配先验（第 10 章起） |
| 图 3.1 横轴是 $x$                                        | 横轴是候选参数值 $A$                                                              |

3. 估计精度从哪里来（3.3 节）

Kay 用同一个例子给了三个层次的解释。

3.1 第一层：误差就是噪声本身

单样本  $x[0] = A + w[0]$ ，取  $\hat{A} = x[0]$ ：

$$E[\hat{A}] = A \text{（无偏）}, \quad \text{var}(\hat{A}) = \sigma^2, \quad \hat{A} - A = w[0]$$

只有一个样本，没有"平均掉噪声"的余地，这次测量偏多少，估计就偏多少。所以"精度"和"噪声强度"在这里是同一个数。

3.2 第二层：似然函数的"尖锐度"（图 3.1）

固定  $x[0] = 3$ ，把  $p(x[0]; A)$  画成  $A$  的函数：

| $\sigma$         | 曲线形状 | 关键数值                                                                                   | 可信区间 $3 \pm 3\sigma$ |
|------------------|------|----------------------------------------------------------------------------------------|----------------------|
| $\sigma_1 = 1/3$ | 又高又尖 | $p_1(3; A=4)\delta = 0.01\delta$ vs<br>$p_1(3; A=3)\delta = 1.20\delta$ , 相差约<br>120 倍 | [2, 4]               |
| $\sigma_2 = 1$   | 又矮又胖 | $A = 2, 3, 4, 5$ 的似然差不多,<br>无法分辨                                                       | [0, 6]               |

**机制：** $\sigma^2$  小  $\Rightarrow$  PDF 对  $A$  依赖强  $\Rightarrow$  一次观测能排除更多候选值  $\Rightarrow$  信息量大。

这正是 3.3 节开头的纲领："the more the PDF is influenced by the unknown parameter, the better we should be able to estimate it."

💡 细节：高斯 PDF 只通过差值  $(x[0] - A)$  依赖两者，所以同一个  $\sigma$  同时扮演两个角色——既是  $x$  围绕  $A$  的散布，也是似然沿  $A$  轴的宽度。这解释了为什么第一层和第二层是同一个数。

### 3.3 第三层：曲率 = Fisher 信息（式 3.3）

$$-\frac{\partial^2 \ln p(x[0]; A)}{\partial A^2} = \frac{1}{\sigma^2} = I(A) \implies \text{var}(\hat{A}) = \sigma^2 = \frac{1}{I(A)}$$

模糊的"accuracy improves"被精确化成  $\text{CRLB} = \sigma^2$ ，且  $\hat{A} = x[0]$  正好达到它。

### 3.4 极限检验

| 极限                            | 似然函数形态                   | 曲率                   | CRLB                          |
|-------------------------------|--------------------------|----------------------|-------------------------------|
| $\sigma^2 \rightarrow 0$      | 退化成 $A = x[0]$ 处的冲激      | $\rightarrow \infty$ | $\rightarrow 0$ , 完美估计        |
| $\sigma^2 \rightarrow \infty$ | 沿 $A$ 方向趋于平坦 (PDF 不依赖参数) | $\rightarrow 0$      | $\rightarrow \infty$ , 无信息可提取 |

## 4. CRLB 定理（3.4 节，Theorem 3.1）

### 4.1 定理陈述

正则条件：  $E \left[ \frac{\partial \ln p(\mathbf{x}; \theta)}{\partial \theta} \right] = 0$  for all  $\theta$

下界：

$$\text{var}(\hat{\theta}) \geq \frac{1}{-E \left[ \frac{\partial^2 \ln p(\mathbf{x}; \theta)}{\partial \theta^2} \right]} = \frac{1}{I(\theta)} \tag{3.6}$$

可达条件（当且仅当）：

$$\frac{\partial \ln p(\mathbf{x}; \theta)}{\partial \theta} = I(\theta)(g(\mathbf{x}) - \theta) \quad (3.7)$$

此时  $\hat{\theta} = g(\mathbf{x})$  即 MVU 估计量，最小方差为  $1/I(\theta)$ 。

## 4.2 $\ln$ 是从哪来的？（完整推导）

$\ln$  不是为了方便才取的，它是从推导里自动长出来的。

从无偏条件出发：

$$\int \hat{\theta}(\mathbf{x}) p(\mathbf{x}; \theta) d\mathbf{x} = \theta$$

两边对  $\theta$  求导（ $\hat{\theta}(\mathbf{x})$  不含  $\theta$ ）：

$$\int \hat{\theta}(\mathbf{x}) \frac{\partial p}{\partial \theta} d\mathbf{x} = 1$$

**问题：**左边不是一个期望（期望必须是“某量  $\times p$  再积分”）。为了凑出  $p$ ，用恒等式：

$$\frac{\partial p}{\partial \theta} = p \cdot \frac{1}{p} \frac{\partial p}{\partial \theta} = p \cdot \frac{\partial \ln p}{\partial \theta}$$

←  $\ln$  就是从这里来的。取对数的作用是：把“密度的绝对变化率”换成“相对变化率”，从而自动带出权重  $p$ 。

于是  $E[\hat{\theta}s] = 1$ ，其中  $s \triangleq \frac{\partial \ln p}{\partial \theta}$  称为 **score**（得分函数）。

## 4.3 正则条件的来历

同样的技巧用在  $\int p d\mathbf{x} = 1$  上：

$$E[s] = \int \frac{\partial \ln p}{\partial \theta} p d\mathbf{x} = \int \frac{\partial p}{\partial \theta} d\mathbf{x} = \frac{\partial}{\partial \theta} \int p d\mathbf{x} = \frac{\partial(1)}{\partial \theta} = 0$$

所以正则条件本质上是“求导与积分可交换”的技术要求。

## 4.4 用 Cauchy-Schwarz 收尾

由  $E[s] = 0$  得  $\text{cov}(\hat{\theta}, s) = E[\hat{\theta}s] - E[\hat{\theta}]E[s] = 1$ 。再由  $\text{cov}^2(X, Y) \leq \text{var}(X)\text{var}(Y)$ ：

$$1 \leq \text{var}(\hat{\theta}) \cdot \underbrace{\text{var}(s)}_{=I(\theta)} \implies \text{var}(\hat{\theta}) \geq \frac{1}{I(\theta)}$$

Cauchy-Schwarz 取等号的条件是  $\hat{\theta} - \theta$  与  $s$  成比例——这正是可达条件 (3.7) 的来源。

## 4.5 与 MLE 的关系

同一个对数似然，两种用法：

|      | 操作                            | 性质                   |
|------|-------------------------------|----------------------|
| MLE  | 令 $s = 0$ , 解出 $\hat{\theta}$ | 对具体一组数据操作, 结果是随机的    |
| CRLB | 对 $s$ 平方再求期望 (对所有可能数据平均)      | 确定的函数, 描述模型平均能提供多少信息 |

深层联系: MLE 是渐近有效的—— $N \rightarrow \infty$  时 MLE 渐近无偏且方差趋于 CRLB (第 7 章)。

## 5. Fisher 信息：怎么算、为什么能提前算

### 5.1 三步配方

$$I(\theta) = -E \left[ \frac{\partial^2 \ln p(\mathbf{x}; \theta)}{\partial \theta^2} \right]$$

1. 写出  $\ln p(\mathbf{x}; \theta)$
2. 对  $\theta$  求两次导
3. 取期望——用模型已知的矩 (如  $E[w[n]] = 0$ 、 $E[w^2[n]] = \sigma^2$ ), 再加负号

### 5.2 三类例子 (按难度递增)

例 A: 二阶导里根本没有  $\mathbf{x}$  (最省事) — Example 3.3

$$\frac{\partial \ln p}{\partial A} = \frac{1}{\sigma^2} \sum_n (x[n] - A) = \frac{N}{\sigma^2} (\bar{x} - A), \quad \frac{\partial^2 \ln p}{\partial A^2} = -\frac{N}{\sigma^2}$$

二阶导是常数,  $\mathbf{x}$  全消失, 期望免费:  $I(A) = N/\sigma^2$ 。 (同时一阶导已是 (3.7) 形式,  $g(\mathbf{x}) = \bar{x} \Rightarrow$  样本均值是 MVU,  $\text{var} = \sigma^2/N$ 。)

例 B: 含  $\mathbf{x}$ , 但被零均值噪声消掉 (最典型) — 通式 (3.14)

见第 7 节详细推导。关键:  $E[x[n] - s[n; \theta]] = E[w[n]] = 0$ , 含数据的那一整项归零。

例 C: 需要用到二阶矩 — Example 3.6 估计  $\sigma^2$

$$\frac{\partial^2 \ln p}{\partial (\sigma^2)^2} = \frac{N}{2\sigma^4} - \frac{1}{\sigma^6} \sum_n (x[n] - A)^2$$

用  $E[(x[n] - A)^2] = \sigma^2$ :

$$E[\cdot] = \frac{N}{2\sigma^4} - \frac{N\sigma^2}{\sigma^6} = -\frac{N}{2\sigma^4} \Rightarrow I(\sigma^2) = \frac{N}{2\sigma^4}, \quad \text{var}(\widehat{\sigma^2}) \geq \frac{2\sigma^4}{N}$$

### 5.3 两个等价公式, 用哪个?

$$I(\theta) = E \left[ \left( \frac{\partial \ln p}{\partial \theta} \right)^2 \right] = -E \left[ \frac{\partial^2 \ln p}{\partial \theta^2} \right] \tag{3.23}$$

实践中几乎总用二阶导版本——二阶导常常不含  $\mathbf{x}$  (如例 A)，期望白送；一阶导平方总要展开算矩，麻烦得多。

## 5.4 为什么能"提前"算出来 ★

这是最关键的概念问题。答案在于期望符号把数据积分掉了：

$$I(\theta) = - \int \frac{\partial^2 \ln p(\mathbf{x}; \theta)}{\partial \theta^2} p(\mathbf{x}; \theta) d\mathbf{x}$$

$\partial^2 \ln p / \partial \theta^2$  确实是随机变量，但  $\int (\cdot) p d\mathbf{x}$  对所有可能出现的数据集做了加权平均，算完  $\mathbf{x}$  已不在结果里，只剩  $\theta$  和模型参数 ( $\sigma^2$ 、 $N$ )。

它是"模型的属性"，不是"某次实验的属性"。类比：你不用真的掷骰子，就能算出均匀骰子点数的方差是 35/12——因为你知道它的概率模型。

物理含义可以这样念：

"如果真值是  $\theta$ ，那么在它会产生所有可能数据集上，对数似然的平均曲率是多少。"

注意  $\theta$  没有被积掉，它作为自由变量留在答案里。所以得到的是一条函数曲线  $I(\theta)$ ——你一次性把"真值取遍所有可能"的情形都算完了。这正是图 2.5 的虚线、图 3.3 的起伏曲线的由来。

## 5.5 可加性

独立样本的 Fisher 信息可加： $I_N(\theta) = N \cdot I_1(\theta)$  (因为  $\ln p$  是连加，求导和期望都保持可加)。这既是计算捷径，也解释了 CRLB 中  $1/N$  因子的来源：每多一个独立样本，就多贡献一份等量的信息。

# 6. 可达条件与有效估计量

## 6.1 (3.7) 的几何图像：对数似然是一条抛物线 ★

把 score 看成  $\theta$  的函数：

$$s(\theta) = I(\theta)(g(\mathbf{x}) - \theta)$$

这是一条直线，斜率  $-I(\theta)$ ，过零点在  $\theta = g(\mathbf{x})$ 。导数是直线  $\Rightarrow$  对数似然本身是抛物线：

$$\ln p(\mathbf{x}; \theta) = \text{const}(\mathbf{x}) - \frac{I}{2}(\theta - g(\mathbf{x}))^2$$

于是全部含义都清楚了：

| 元素              | 含义                                       |
|-----------------|------------------------------------------|
| $g(\mathbf{x})$ | 抛物线顶点的位置。数据变了，整条抛物线左右平移，顶点跟着数据走          |
| $I(\theta)$     | 抛物线的开口（曲率），不随数据变 $\Rightarrow$ 精度固定、事先可知 |
| 数据的作用           | 只负责"指定顶点位置"，其余形状不变                       |

(3.7) 的苛刻之处： $\theta$  只能以"孤零零被减掉"的方式出现，外面再乘一个纯  $\theta$  的系数。数据和参数必须干净地分离。

## 6.2 $g(\mathbf{x})$ 到底是什么

它就是把 score 因式分解后剩下的那个"只含数据、不含  $\theta$ "的函数。不是你事先挑的，而是算出来的。

$\hat{\theta} = g(\mathbf{x})$  这一步是定义/选择，不是推导出来的——定理在宣布"把估计量取成这个函数"。定理的实质内容是：这样取出来的估计量恰好无偏、且方差正好等于  $1/I(\theta)$ 。

为什么这是唯一合理的选择？三个角度：

1. 抛物线顶点：令  $\text{score} = 0$  (MLE)  $\Rightarrow \theta = g(\mathbf{x})$ 。数据唯一"指认"出来的那个  $\theta$  值
2. 零点应在真值附近：正则条件说在真值处  $E[s] = 0$ ，而  $g(\mathbf{x})$  正是本次数据给出的零点
3. Cauchy-Schwarz 等号条件：要求  $\hat{\theta} - \theta = \frac{1}{I(\theta)}s$ ，对照可知  $\hat{\theta}$  只能是  $g(\mathbf{x})$

✦  $g(\mathbf{x})$  不含  $\theta$  是关键——这才使它能当估计量用。含  $\theta$  的表达式你算不出来。✦ MVU 估计量（在几乎处处意义下）唯一，所以不存在"另一个也能达到下界的估计量"。

## 6.3 三个"白送"的性质

从 (3.7) 出发，三件事不用另外验证：

① 一定无偏。由  $E[s] = 0$ ：

$$0 = E[I(\theta)(g - \theta)] = I(\theta)(E[g] - \theta) \Rightarrow E[g(\mathbf{x})] = \theta$$

② 分解出的乘子就是 Fisher 信息。设分解为  $s = c(\theta)(g - \theta)$ ，则

$$-E\left[\frac{\partial s}{\partial \theta}\right] = -E[c'(\theta)(g - \theta) - c(\theta)] = -c'(\theta)\underbrace{E[g - \theta]}_{=0} + c(\theta) = c(\theta)$$

所以不需要事先知道  $I(\theta)$ ，随手分解出的系数就是它。

③ 方差正好等于下界： $\text{var}(s) = I(\theta)$  且  $\text{var}(s) = I^2(\theta)\text{var}(g) \Rightarrow \text{var}(g) = 1/I(\theta)$ 。

无偏 + 方差达到 CRLB  $\Rightarrow$  它就是 MVU。这就是"CRLB 理论顺带把估计量给出来"的意思。

## 6.4 式 (3.10) 那半页证明在干什么

它在补一个记号上的漏洞：定理 3.1 说 (3.7) 中的  $I$  只是 "some function"，凭什么它就等于  $-E[\partial^2 \ln p / \partial \theta^2]$ ？上面 ② 就是答案（书上用  $\hat{\theta}$  代替  $g(\mathbf{x})$  走了一遍）。

两个关键点：

- $\hat{\theta} = g(\mathbf{x})$  不含  $\theta$ ，所以  $\partial \hat{\theta} / \partial \theta = 0$ ，乘积法则只出两项
- 无偏性杀掉了  $I'(\theta)$  那一项，哪怕  $I(\theta)$  随  $\theta$  变化也无妨

实用价值：若 (3.7) 能配出来，不必再算二阶导和期望，直接读系数。Example 3.3 一次求导即同时拿到估计量、Fisher 信息、最小方差，并已证明是 MVU。

## 6.5 配不出来怎么办

若  $\theta$  缠在数据里出不来（如 Example 3.4 相位估计、Example 3.5 频率估计），则有效估计量不存在。此时：

- CRLB 仍可算，作为性能基准
- 找 MVU 需转第 5 章 RBLS 定理（充分统计量）
- 或退而求其次：第 6 章 BLUE（限定线性）、第 7 章 MLE（渐近有效）

---

## 7. WGN 中信号的通用 CRLB (3.5 节)

---

### 7.1 模型与推导

$$x[n] = s[n; \theta] + w[n], \quad w[n] \sim \text{WGN}(0, \sigma^2), \quad n = 0, \dots, N-1$$

记  $s'[n] \triangleq \partial s[n; \theta] / \partial \theta$ ,  $s''[n] \triangleq \partial^2 s[n; \theta] / \partial \theta^2$ 。

一阶导（链式法则，内导数带负号，两个负号相消）：

$$\frac{\partial \ln p}{\partial \theta} = \frac{1}{\sigma^2} \sum_{n=0}^{N-1} (x[n] - s[n; \theta]) s'[n]$$

二阶导（乘积法则，两个因子都含  $\theta$ ）：

$$\begin{aligned} \frac{\partial}{\partial \theta} [(x[n] - s) s'] &= \underbrace{(-s') \cdot s'}_{\text{第一因子求导}} + \underbrace{(x[n] - s) \cdot s''}_{\text{第二因子求导}} \\ \frac{\partial^2 \ln p}{\partial \theta^2} &= \frac{1}{\sigma^2} \sum_{n=0}^{N-1} \left\{ (x[n] - s[n; \theta]) s''[n] - (s'[n])^2 \right\} \end{aligned}$$

### 7.2 取期望：为什么结果只剩信号 ★

先分清谁是随机的：

| 量                                   | 随机吗 | 理由                              |
|-------------------------------------|-----|---------------------------------|
| $x[n]$                              | 是   | 含噪声                             |
| $s[n; \theta]$ 、 $s'[n]$ 、 $s''[n]$ | 否   | 已知信号模型及其导数，只是 $n, \theta$ 的确定函数 |
| $\sigma^2, N$                       | 否   | 模型参数                            |

整个二阶导里唯一的随机成分是  $x[n]$ ，且以一次方（线性）出现——这意味着只需噪声的一阶矩。

第一项： $s''[n]$  确定可提出，而

$$x[n] - s[n; \theta] = w[n] \implies E[x[n] - s[n; \theta]] = E[w[n]] = 0$$

$\implies$  整块归零， $s''$  无论多复杂都无所谓。

第二项： $(s'[n])^2$  完全确定，期望就是自身。

$$E \left[ \frac{\partial^2 \ln p}{\partial \theta^2} \right] = -\frac{1}{\sigma^2} \sum_{n=0}^{N-1} (s'[n])^2$$

$$\boxed{\text{var}(\hat{\theta}) \geq \frac{\sigma^2}{\sum_{n=0}^{N-1} \left( \frac{\partial s[n; \theta]}{\partial \theta} \right)^2}} \quad (3.14)$$

### 7.3 ⚠ 关键细节：为什么 $x[n] - s[n; \theta]$ 恰好是噪声

这依赖定理 3.1 里一句容易被略过的话：

*"the derivative is evaluated at the **true value of  $\theta$**  and the expectation is taken with respect to  $p(\mathbf{x}; \theta)$ "*

两处的  $\theta$  是同一个值。求导后代入的  $\theta$  是真值，取期望时数据分布也由这同一个真值产生，于是  $E_\theta[x[n]] = s[n; \theta]$ ，残差正好是纯噪声。

若代入  $\theta' \neq \theta$ ：

$$x[n] - s[n; \theta'] = \underbrace{s[n; \theta] - s[n; \theta']}_{\neq 0, \text{确定性偏差}} + w[n]$$

均值不为零，第一项不会消失，(3.14) 也就不成立。

所以"在真值处求值"不是可有可无的措辞，而是这步化简的前提。这也解释了 CRLB 为什么是  $\theta$  的函数：每个候选真值对应一次独立的计算。

### 7.4 交叉验证：换一条路算

用  $I(\theta) = E[(\partial \ln p / \partial \theta)^2]$ ，把一阶导写成噪声形式  $\frac{1}{\sigma^2} \sum_n w[n] s'[n]$ ：

I(theta) = 1/sigma^4 \* sum\_n sum\_m s'[n] s'[m] E[w[n] w[m]] = 1/sigma^2 \* sum\_n (s'[n])^2

两条路径用到的假设不同，很有启发：

| 路径    | 用到的噪声假设                                                    |
|-------|------------------------------------------------------------|
| 二阶导   | 仅 $E[w[n]] = 0$ （零均值）                                      |
| 一阶导平方 | $E[w[n]w[m]] = \sigma^2\delta[n - m]$ （零均值 + 白，交叉项因不相关而消失） |

高斯性在更早就用掉了——它决定了  $\ln p$  是二次型。

7.5 结果怎么读：几何图像

var(hat(theta)) >= (噪声功率) / (信号对参数的敏感度能量)

把  $\mathbf{s}(\theta) = [s[0; \theta], \dots, s[N - 1; \theta]]^T$  看成  $\mathbb{R}^N$  中随  $\theta$  移动的曲线：

- $\mathbf{s}'(\theta)$  是切向量， $\|\mathbf{s}'\|^2 = \sum (s'[n])^2$  是曲线的移动速度
- 噪声把观测点模糊成半径约  $\sigma$  的球
- 速度快  $\Rightarrow$  不同  $\theta$  对应的信号点拉得开  $\Rightarrow$  噪声球不重叠  $\Rightarrow$  好估

CRLB = 噪声球半径 ÷ 曲线速度。这就是 Kay 那句 "Signals that change rapidly as the unknown parameter changes result in accurate estimators" 的数学形式。

💡 结构性观察：曲线的弯曲程度  $s''$  完全不影响 CRLB，它在平均意义下被噪声抹掉了。但对某一次具体的数据， $\partial^2 \ln p / \partial \theta^2$  里确实还挂着  $w[n]s''[n]$ ——观测曲率围绕平均曲率随机起伏，Fisher 信息取的是平均值。这再次说明  $E[\cdot]$  不是装饰。

7.6 例题速查表

| 例   | 参数               | $s[n; \theta]$              | $\partial s / \partial \theta$      | $\sum (\partial s / \partial \theta)^2$ | CRLB                                 |
|-----|------------------|-----------------------------|-------------------------------------|-----------------------------------------|--------------------------------------|
| 3.3 | DC 电平 $A$        | $A$                         | 1                                   | $N$                                     | $\sigma^2 / N$                       |
| 3.4 | 相位 $\phi$        | $A \cos(2\pi f_0 n + \phi)$ | $-A \sin(2\pi f_0 n + \phi)$        | $\approx NA^2 / 2$                      | $2\sigma^2 / (NA^2)$                 |
| 3.5 | 频率 $f_0$         | $A \cos(2\pi f_0 n + \phi)$ | $-2\pi n A \sin(2\pi f_0 n + \phi)$ | $A^2 \sum [2\pi n \sin(\cdot)]^2$       | 式 (3.15)                             |
| 3.6 | 方差 $\sigma^2$    | —                           | —                                   | —                                       | $2\sigma^4 / N$                      |
| 3.7 | 截距 $A$ ( $B$ 未知) | $A + Bn$                    | 1                                   | —                                       | $\frac{2(2N - 1)\sigma^2}{N(N + 1)}$ |
| 3.7 | 斜率 $B$ ( $A$ 未知) | $A + Bn$                    | $n$                                 | —                                       | $\frac{12\sigma^2}{N(N^2 - 1)}$      |

频率行的  $n$  因子说明为什么**频率比相位好估得多** ( $1/N^3$  vs  $1/N$ ): 时间越靠后的采样点对频率误差越敏感, 相位误差随  $n$  线性累积。同样的机制解释了 Example 3.7 里斜率  $B$  比截距  $A$  好估。

Example 3.7 还给出一条通则: **估计的参数越多, CRLB 越大** ( $A$  的界从  $\sigma^2/N$  涨到  $\frac{2(2N-1)\sigma^2}{N(N+1)}$ )。

## 8. Example 3.4 完整拆解 (相位估计)

这是全章代数最繁的一例, 专门列出。

### 8.1 记号

$$\alpha_n \triangleq 2\pi f_0 n + \phi, \quad \frac{\partial \alpha_n}{\partial \phi} = 1, \quad 4\pi f_0 n + 2\phi = 2\alpha_n$$

### 8.2 求导公式表 (注意内导数)

| 式子               | 对 $\phi$ 求导         | 内导数 |
|------------------|---------------------|-----|
| $\cos \alpha_n$  | $-\sin \alpha_n$    | 1   |
| $\sin \alpha_n$  | $\cos \alpha_n$     | 1   |
| $\sin 2\alpha_n$ | $2 \cos 2\alpha_n$  | 2   |
| $\cos 2\alpha_n$ | $-2 \sin 2\alpha_n$ | 2   |

⚠ 那个 2 是后面所有系数对得上的关键, 漏了就全错。

### 8.3 三角恒等式: 两条, 都是积化和差的特例

$$\sin A \cos B = \frac{1}{2} [\sin(A+B) + \sin(A-B)] \xrightarrow{A=B=\alpha} \boxed{\sin \alpha \cos \alpha = \frac{1}{2} \sin 2\alpha} \quad (\text{二倍角})$$

$$\cos A \cos B = \frac{1}{2} [\cos(A+B) + \cos(A-B)] \xrightarrow{A=B=\alpha} \boxed{\cos^2 \alpha = \frac{1}{2} + \frac{1}{2} \cos 2\alpha} \quad (\text{降幂})$$

"积化和差"和"二倍角"在这里是同一条公式的两次使用: 把两个正弦量的乘积拆成"直流项 + 二倍频项"。这是整个推导的物理主线。

### 8.4 六步推导

① **一阶导** (链式法则,  $-A \cdot (-\sin \alpha_n) = +A \sin \alpha_n$ , 系数 2 与  $\frac{1}{2\sigma^2}$  约掉):

$$\frac{\partial \ln p}{\partial \phi} = -\frac{1}{\sigma^2} \sum_n [x[n] - A \cos \alpha_n] A \sin \alpha_n$$

② **展开 + 二倍角** (信号自乘产生二倍频分量):

$$= -\frac{A}{\sigma^2} \sum_n \left[ x[n] \sin \alpha_n - \frac{A}{2} \sin 2\alpha_n \right]$$

③ 二阶导 ( $\frac{1}{2}$  被内导数的 2 吃掉, 所以系数是干净的  $A$ ):

$$\frac{\partial^2 \ln p}{\partial \phi^2} = -\frac{A}{\sigma^2} \sum_n [x[n] \cos \alpha_n - A \cos 2\alpha_n]$$

④ 取负期望 ( $E[x[n]] = A \cos \alpha_n$ , 平方项出现):

$$-E \left[ \frac{\partial^2 \ln p}{\partial \phi^2} \right] = \frac{A}{\sigma^2} \sum_n [A \cos^2 \alpha_n - A \cos 2\alpha_n]$$

⑤ 降幂公式:

$$= \frac{A^2}{\sigma^2} \sum_n \left[ \underbrace{\frac{1}{2}}_{\text{直流}} + \frac{1}{2} \cos 2\alpha_n - \cos 2\alpha_n \right] = \frac{A^2}{\sigma^2} \left[ \frac{N}{2} - \frac{1}{2} \sum_n \cos(4\pi f_0 n + 2\phi) \right]$$

到这里完全精确, 没有任何近似。

⑥ 二倍频项的抵消 (唯一的近似):

由几何级数求和 (Dirichlet 核):

$$\left| \sum_{n=0}^{N-1} \cos(4\pi f_0 n + 2\phi) \right| = \left| \frac{\sin(2\pi f_0 N)}{\sin(2\pi f_0)} \right| \leq \frac{1}{|\sin(2\pi f_0)|}$$

右边与  $N$  无关, 是有界常数, 除以  $N$  后趋于 0。

直觉: 余弦累加很多个周期, 正负半周互相抵消, 只剩末尾不满一周期的零头 ( $O(1)$ ), 而直流项累积成  $O(N)$ 。

$$I(\phi) \approx \frac{NA^2}{2\sigma^2} \implies \boxed{\text{var}(\hat{\phi}) \geq \frac{2\sigma^2}{NA^2} = \frac{1}{N\eta}}, \quad \eta \triangleq \frac{A^2}{2\sigma^2} \text{ (SNR)}$$

相位估计精度只取决于总信噪比  $N\eta$ , 与频率  $f_0$  无关 (只要不在 0 或  $1/2$  附近)。

## 8.5 为什么要求 $f_0$ 不接近 0 或 $1/2$

因为分母  $\sin(2\pi f_0)$  在这两处为零。此时  $2f_0$  落在整数倍频,  $\cos(4\pi f_0 n + 2\phi)$  退化成常数, 不振荡、不抵消。

取  $f_0 \rightarrow 0$  精确计算:

$$I(\phi) = \frac{A^2}{\sigma^2} \cdot \frac{N}{2} (1 - \cos 2\phi) = \frac{NA^2 \sin^2 \phi}{\sigma^2}$$

在  $\phi = 0$  处  $I = 0$ , CRLB 发散——**相位完全不可估**。物理上合理:  $f_0 = 0$  时信号是常数  $A \cos \phi$ , 而  $\phi = 0$  恰是余弦极值点,  $\phi$  的一阶扰动不改变信号。

## 8.6 捷径: 用 (3.14) 三行搞定

$$s[n; \phi] = A \cos \alpha_n \Rightarrow \frac{\partial s}{\partial \phi} = -A \sin \alpha_n \Rightarrow I(\phi) = \frac{A^2}{\sigma^2} \sum_n \sin^2 \alpha_n \approx \frac{A^2}{\sigma^2} \cdot \frac{N}{2}$$

(用了  $\overline{\sin^2} = 1/2$ , 还是同一条降幂公式。) (3.14) 已经把"期望消掉含数据项"这一步一次性做完了。

## 8.7 这个例子的真正用意

看 ② 式的 score:  $\phi$  被锁在  $\sin(\cdot)$  里面, 与数据  $x[n]$  缠在一起, 无论如何配不成  $I(\phi)(g(\mathbf{x}) - \phi)$ 。

$\Rightarrow$  按定理 3.1 的"当且仅当": 有效估计量不存在, CRLB 够不着。这就是 Kay 预告的 "the CRLB is not always satisfied", 对应图 2.5 里  $\hat{\theta}_1$  贴不到虚线的情形。

## 9. 参数变换 (3.6 节)

### 9.1 这一节在干什么

- 3.5: 在具体模型下怎么把 CRLB 算出来
- 3.6: CRLB 已算好, 但你真正想估的不是模型里那个参数, 而是它的某个函数——界怎么换算, 代价是什么

它不是新的推导方法, 而是一个换算规则 + 一条警告。

### 9.2 动机: 模型参数 $\neq$ 你关心的量

模型  $x[n] = A + w[n]$  里天然出现的是  $A$ , 但实际可能关心:

- 信号功率  $A^2$  (雷达回波强度)
- 分贝值  $20 \log_{10} |A|$
- 阵列测向中模型参数是空间频率  $u = \sin \theta$ , 你要的是角度  $\theta$
- 模型参数是  $\sigma^2$ , 你要标准差  $\sigma$

难道每换一个关心的量就要重写似然、重新求二阶导? 3.6 说: 不用。

### 9.3 规则 (3.16): 就是误差传播公式

若  $\alpha = g(\theta)$ :

$$\text{var}(\hat{\alpha}) \geq \frac{(\partial g / \partial \theta)^2}{I(\theta)} = \left( \frac{\partial g}{\partial \theta} \right)^2 \cdot \text{CRLB}(\theta) \quad (3.16)$$

Fisher 信息只算一次 (在最方便的参数化下), 换算时乘一个  $(g')^2$ 。

本质就是一阶误差传播:  $\delta \alpha \approx g'(\theta) \delta \theta$ , 两边平方取期望, 方差乘  $(g')^2$ 。

生活化类比: 卡尺测半径精度  $\pm 0.1$  mm, 问圆面积精度?  $S = \pi r^2$ ,  $dS/dr = 2\pi r$ , 所以  $\sigma_S = 2\pi r \cdot 0.1$ 。不需要重新标定一把"测面积的尺子"。

书上的例子:  $I(A) = N/\sigma^2$ ,  $g(A) = A^2$ ,  $g' = 2A$ :

$$\text{var}(\widehat{A^2}) \geq \frac{(2A)^2}{N/\sigma^2} = \frac{4A^2\sigma^2}{N} \quad (3.17)$$

★ 注意结果里出现的是原参数  $A$  ("the CRLB is expressed in terms of  $\theta$ "). 必然如此, 因为 Fisher 信息本来就是关于  $\theta$  定义的。

## 9.4 代价: 非线性变换毁掉有效性 ⚠

$\bar{x}$  对  $A$  是有效估计量。那么估  $A^2$  时直接代入, 用  $\bar{x}^2$  行不行?

不行——它连无偏都不是:

$$E[\bar{x}^2] = E^2[\bar{x}] + \text{var}(\bar{x}) = A^2 + \frac{\sigma^2}{N} \neq A^2 \quad (3.18)$$

偏差从哪来? 二阶 Taylor 展开一目了然:

$$g(\bar{x}) \approx g(A) + g'(A)(\bar{x} - A) + \frac{1}{2}g''(A)(\bar{x} - A)^2$$

取期望, 一阶项因无偏而消失:

$$E[g(\bar{x})] \approx g(A) + \underbrace{\frac{1}{2}g''(A)\text{var}(\bar{x})}_{\text{偏差}}$$

代入  $g'' = 2$ 、 $\text{var}(\bar{x}) = \sigma^2/N$ , 正好得到  $\sigma^2/N$  ✓

根源是  $g$  的弯曲 ( $g'' \neq 0$ ): 估计值在真值两侧随机抖动, 经弯曲函数映射后两侧不再对称抵消, 系统性偏向凸的一边 (Jensen 不等式:  $g$  凸时  $E[g(\hat{\theta})] \geq g(E[\hat{\theta}])$ )。线性函数没有弯曲, 不受影响。

即使去偏成  $\bar{x}^2 - \sigma^2/N$ , 方差仍是

$$\frac{4A^2\sigma^2}{N} + \frac{2\sigma^4}{N^2} > \underbrace{\frac{4A^2\sigma^2}{N}}_{\text{CRLB}}$$

有效性确实丢了, 不只是无偏性的问题。

## 9.5 线性 (仿射) 变换则完好无损

$\alpha = a\theta + b$ , 取  $\hat{\alpha} = a\hat{\theta} + b$ :

- 无偏:  $E[a\hat{\theta} + b] = a\theta + b = \alpha$  ✓
- 方差:  $\text{var}(a\hat{\theta} + b) = a^2\text{var}(\hat{\theta})$
- CRLB 按 (3.16) 也乘  $a^2$

两边同步缩放, 等号保持。单位换算、加偏置这类操作是安全的。

## 9.6 大样本下近似恢复: 统计线性化 (图 3.4)

$N$  增大  $\Rightarrow \bar{x}$  的 PDF 集中在  $A \pm 3\sigma/\sqrt{N}$  的小区间  $\Rightarrow$  在这小区间内, 再弯的  $g$  也近似是直的  $\Rightarrow$  非线性退化为线性, 无偏性与有效性近似恢复:

$$\text{var}(\bar{x}^2) = \frac{4A^2\sigma^2}{N} + \underbrace{\frac{2\sigma^4}{N^2}}_{\text{比第一项快一阶趋于0}} \rightarrow \text{CRLB} \quad (3.19)$$

$\Rightarrow \bar{x}^2$  是  $A^2$  的渐近有效估计量。实践中"直接代入"通常可接受，但要知道自己在做近似，且  $N$  小时它是有偏的。

## 9.7 小结表

|                        | 线性变换 $a\theta + b$      | 非线性变换 $g(\theta)$                                              |
|------------------------|-------------------------|----------------------------------------------------------------|
| CRLB 换算                | $a^2 \cdot \text{CRLB}$ | $(g')^2 \cdot \text{CRLB}$ ((3.16), 总成立)                       |
| 无偏性                    | 保持                      | 破坏, 偏差 $\approx \frac{1}{2}g'' \cdot \text{var}(\hat{\theta})$ |
| 有效性                    | 保持                      | 破坏, 但 $N \rightarrow \infty$ 渐近恢复                              |
| 直接代入 $g(\hat{\theta})$ | 放心用                     | 小样本当心, 大样本可用                                                   |

一句话记住 3.6: 界可以用链式法则换算, 但"最优性"不能跟着一起搬家。

## 9.8 它在全书中的位置

- 通向第 7 章 MLE: MLE 有不变性—— $g(\theta)$  的 MLE 就是  $g(\hat{\theta}_{\text{MLE}})$ , 直接代入即可。3.6 解释了为什么这个性质在有限样本下只是近似、大样本下才严格有效
- 通向 3.7/3.8 向量版: 多参数下  $(g')^2$  换成 Jacobian 夹逼  $\frac{\partial \mathbf{g}}{\partial \boldsymbol{\theta}} \mathbf{I}^{-1}(\boldsymbol{\theta}) \frac{\partial \mathbf{g}}{\partial \boldsymbol{\theta}}^T$  (式 3.30)

## 10. 概念澄清：我们提前知道真值吗？★

这是学 CRLB 最关键的一道坎。不知道，但"分析性能"和"做估计"是两件事。

|      | 谁             | 知道 $\theta$ 吗 | 在干什么                                    |
|------|---------------|---------------|-----------------------------------------|
| 估计   | 系统/算法 (运行时)   | 不知道           | 拿到数据, 算出 $\hat{\theta} = g(\mathbf{x})$ |
| 性能分析 | 工程师 (设计时, 纸上) | 假设它是某值        | 回答"如果真值是 $\theta$ , 这套方案能准到什么程度"        |

运行估计时完全不需要  $\theta$ —— $\hat{\theta} = \bar{x}$  这个公式里没有  $\theta$ , 只有数据。这正是要求  $g(\mathbf{x})$  只含数据的原因。

而 CRLB 是一个条件命题:

"假如真值是  $\theta$ , 那么任何无偏估计量的方差不会低于  $1/I(\theta)$ 。"

这是设计阶段在纸上做的推演。这也解释了图 2.5 的虚线为什么画成  $\theta$  的函数——它遍历了所有可能的真值。

## 类比

游标卡尺说明书写"精度  $\pm 0.02 \text{ mm}$ ":

- 这是**仪器的规格**，厂家不知道你要测什么就标定好了
- 你测未知零件，读数  $12.34 \text{ mm}$ 。不知道真值，但知道真值大概率在  $12.34 \pm 0.02$  内

CRLB 就是估计问题的"精度规格"， $\hat{\theta}$  才是"读数"。

## 那这个规格有什么用？

① **可行性论证（工程上最值钱）** 造任何东西之前就能回答"能不能达标"。如  $\text{var}(\hat{A}) \geq \sigma^2/N$ ：要求标准差  $\leq 0.01$ 、 $\sigma = 1$ ，立刻得  $N \geq 10^4$ 。如果 CRLB 都达不到指标，方案物理上不可能实现，趁早改设计，别浪费三个月调算法。

② **判断算法还有没有优化空间** 仿真方差是  $1.02\sigma^2/N$  而 CRLB 是  $\sigma^2/N \Rightarrow$  收工，没有无偏估计量能更好。若是 CRLB 的 10 倍  $\Rightarrow$  有信息没榨干。没有 CRLB，你永远不知道该停在哪。

③ **指出"哪里难估、为什么难"** Example 3.5 告诉你低频段本质上难估（不是你算法烂）；Example 3.7 告诉你斜率比截距好估、参数越多界越大。这些直接指导**波形/系统设计**——既然性能取决于  $\sum(\partial s/\partial \theta)^2$ ，就把信号设计成对参数敏感的形状。

④ 顺带给出估计量——(3.7) 的分解。

## "CRLB 依赖未知的 $\theta$ "怎么办

1. 运气好，根本不依赖。如  $\sigma^2/N$  对所有  $A$  相同（Example 3.2 特意写了 "for all  $A$ "）
2. 依赖就画出整条曲线（图 3.3），按工作区间内**最坏情况**设计
3. 把估计值代回去：用  $I(\hat{\theta})^{-1}$  作为本次测量的**误差棒**。实际系统（雷达、GPS、定位算法）报告的精度基本都这么来的

仿真时你**确实知道真值**（自己生成的），所以能算经验方差验证。真实部署时不知道——正因如此才需要一个**纯靠模型推导、不依赖实测**的性能理论。CRLB 让你省掉"先造出来再看行不行"的昂贵弯路。

11. 常见误区汇总

| ✖ 误区                                    | ✔ 正确                                                                                                            |
|-----------------------------------------|-----------------------------------------------------------------------------------------------------------------|
| 无偏就是好估计量                                | 无偏只保证平均命中；方差大照样烂。看 $mse = var + bias^2$                                                                         |
| 平均更多估计能消除偏差                             | 只能消方差。偏差是相干叠加， $n$ 个 $b$ 除以 $n$ 还是 $b$                                                                          |
| 似然函数是 $\theta$ 的概率                      | 不是密度、不积分为 1、可大于 1。只有相对大小有意义                                                                                     |
| 图 3.1 横轴是数据                             | 横轴是候选参数 $A$                                                                                                     |
| CRLB 达不到 $\Rightarrow$ MVU 不存在          | 只是充分条件。贴到界上一定是 MVU；贴不上只说明这条路失败（图 2.5 的 $\hat{\theta}_1$ ）                                                       |
| CRLB 对所有估计量成立                           | 只对无偏估计量。有偏估计方差可低于 CRLB（极端例： $\hat{\theta} \equiv 0$ 方差为零），代价是偏差。有偏版本分子要乘 $(1 + \partial b / \partial \theta)^2$ |
| CRLB 需要先测量才能算                           | 期望把数据积分掉了，它是模型的属性。纸上即可算出整条曲线                                                                                    |
| (3.14) 对任何 $\theta$ 值都成立                | 必须在真值处求值，否则 $x[n] - s[n; \theta']$ 不是零均值，含数据项不消失                                                                |
| 有效估计量的 $g$ 可以随便选                        | $g$ 是因式分解被迫剩下的，且必须不含 $\theta$ 。MVU 唯一                                                                           |
| 估 $g(\theta)$ 直接代入 $g(\hat{\theta})$ 就行 | 非线性变换破坏无偏与有效（大样本才近似成立）                                                                                          |
| Fisher 信息越大，估计越差                        | 反了。 $I$ 大 $\Rightarrow$ 似然尖 $\Rightarrow$ 界 $1/I$ 小 $\Rightarrow$ 越准                                            |

12. 公式速查表

基础

| 名称                | 公式                                                                          |
|-------------------|-----------------------------------------------------------------------------|
| 偏差                | $b(\theta) = E(\hat{\theta}) - \theta$                                      |
| MSE 分解            | $mse(\hat{\theta}) = var(\hat{\theta}) + b^2(\theta)$                       |
| 平均 $n$ 个独立同方差无偏估计 | $E(\hat{\theta}) = \theta, \quad var(\hat{\theta}) = var(\hat{\theta}_1)/n$ |

CRLB 核心

| 名称        | 公式                                                                                                                                                                     |
|-----------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 正则条件      | $E \left[ \frac{\partial \ln p}{\partial \theta} \right] = 0$ for all $\theta$                                                                                         |
| score     | $s = \frac{\partial \ln p(\mathbf{x}; \theta)}{\partial \theta}, \quad E[s] = 0$                                                                                       |
| Fisher 信息 | $I(\theta) = -E \left[ \frac{\partial^2 \ln p}{\partial \theta^2} \right] = E \left[ \left( \frac{\partial \ln p}{\partial \theta} \right)^2 \right]$                  |
| CRLB      | $\text{var}(\hat{\theta}) \geq 1/I(\theta)$                                                                                                                            |
| 可加性       | $I_N(\theta) = N \cdot I_1(\theta)$ (独立样本)                                                                                                                             |
| 可达条件      | $\frac{\partial \ln p}{\partial \theta} = I(\theta)(g(\mathbf{x}) - \theta) \Rightarrow \hat{\theta} = g(\mathbf{x})$ 为 MVU                                            |
| WGN 中信号通式 | $\text{var}(\hat{\theta}) \geq \frac{\sigma^2}{\sum_n (\partial s[n; \theta] / \partial \theta)^2}$                                                                    |
| 参数变换      | $\text{var}(\hat{\alpha}) \geq \frac{(\partial g / \partial \theta)^2}{I(\theta)}, \quad \alpha = g(\theta)$                                                           |
| 向量版       | $\mathbf{C}_{\hat{\theta}} - \mathbf{I}^{-1}(\theta) \geq 0, \quad [\mathbf{I}]_{ij} = -E \left[ \frac{\partial^2 \ln p}{\partial \theta_i \partial \theta_j} \right]$ |

常用数学工具

| 用途               | 公式                                                                                                                              |
|------------------|---------------------------------------------------------------------------------------------------------------------------------|
| ln 的来历           | $\frac{\partial p}{\partial \theta} = p \cdot \frac{\partial \ln p}{\partial \theta}$                                           |
| 二倍角              | $\sin \alpha \cos \alpha = \frac{1}{2} \sin 2\alpha$                                                                            |
| 降幂               | $\cos^2 \alpha = \frac{1}{2} + \frac{1}{2} \cos 2\alpha, \quad \sin^2 \alpha = \frac{1}{2} - \frac{1}{2} \cos 2\alpha$          |
| 积化和差             | $\sin A \cos B = \frac{1}{2} [\sin(A+B) + \sin(A-B)]; \quad \cos A \cos B = \frac{1}{2} [\cos(A+B) + \cos(A-B)]$                |
| 正弦求和 (Dirichlet) | $\left\  \sum_{n=0}^{N-1} \cos(2\pi f n + \psi) \right\  \leq \frac{1}{\ \sin \pi f\ }$ (与 $N$ 无关)                              |
| 非线性变换偏差          | $E[g(\hat{\theta})] \approx g(\theta) + \frac{1}{2} g''(\theta) \text{var}(\hat{\theta})$                                       |
| 高斯四阶矩            | $\xi \sim \mathcal{N}(\mu, \sigma^2): \quad E[\xi^2] = \mu^2 + \sigma^2, \quad \text{var}(\xi^2) = 4\mu^2 \sigma^2 + 2\sigma^4$ |
| 高斯对数似然           | $\ln p = -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_n (x[n] - s[n; \theta])^2$                                   |

13. 解题流程（拿到新问题按此走）

1. 写出  $p(\mathbf{x};\theta)$  → 取对数 → 求一阶导  $\partial \ln p / \partial \theta$

↓

2. 【先试】能否配成  $I(\theta) \cdot (g(\mathbf{x}) - \theta)$  ?

├ 能 → 同时读出:

├ |

├ |     •  $I(\theta)$  = 提出的系数

├ |     • MVU 估计量  $\hat{\theta} = g(\mathbf{x})$

├ |     • 最小方差 =  $1/I(\theta)$

├ |     【收工】

└ 不能 → 3. 继续求二阶导, 取期望得  $I(\theta)$

(WGN 中的信号可直接套 (3.14) 跳过此步)

↓

4. 得到 CRLB, 作为性能基准使用

↓

5. 有效估计量不存在。若仍要找 MVU:

├ 第 5 章 RBLS (充分统计量)

├ 第 6 章 BLUE (限定线性)

├ 第 7 章 MLE (渐近有效, 大样本首选)

↓

6. 若关心的是  $\alpha = g(\theta)$ : 套 (3.16) 乘  $(\partial g / \partial \theta)^2$

⚠ 非线性时注意无偏/有效性会丢失

14. 与后续章节的连接

| 章节      | 内容                        | 与本部分的关系                                                                 |
|---------|---------------------------|-------------------------------------------------------------------------|
| 3.7-3.8 | 向量参数 CRLB、Fisher 信息矩阵     | 标量结论的矩阵推广; "参数越多界越大"                                                    |
| 3.9     | WSS 高斯过程的渐近 CRLB (基于 PSD) | 大数据记录下的实用形式                                                             |
| 第 4 章   | 线性模型                      | CRLB 必定可达的一大类模型                                                         |
| 第 5 章   | 充分统计量、RBLS 定理             | CRLB 够不着时找 MVU 的第二条路                                                    |
| 第 6 章   | BLUE                      | 限定线性, 牺牲最优性换可解性                                                         |
| 第 7 章   | MLE                       | 渐近无偏、渐近有效 (渐近达到 CRLB) + 不变性 (呼应 3.6)                                    |
| 第 10 章起 | 贝叶斯方法                     | 记号从 $p(\mathbf{x};\theta)$ 变为 $p(\mathbf{x}  \theta)$ + 先验; 界变为贝叶斯 CRLB |

## 附：一页速记

---

1.  $\text{mse} = \text{var} + \text{bias}^2$ ，偏差平方相加无交叉项（正交分解）
2. 平均只压方差不压偏差  $\Rightarrow$  先强制无偏，再最小化方差  $\Rightarrow$  MVU
3. 似然 = 把 PDF 反过来看，固定数据、变参数，给候选  $\theta$  打分
4. 精度  $\leftarrow$  似然的尖锐度  $\leftarrow$  对数似然的曲率  $\leftarrow$  Fisher 信息  $I(\theta)$
5.  $\ln$  来自  $\partial p / \partial \theta = p \cdot \partial \ln p / \partial \theta$ ，是为了把导数变回期望形式
6. CRLB:  $\text{var}(\hat{\theta}) \geq 1/I(\theta)$ ，只对无偏估计量成立
7.  $I(\theta)$  能提前算，因为期望把数据积分掉了——它是模型的属性，不是实验的属性
8. 可达  $\Leftrightarrow$  对数似然恰为抛物线，顶点  $g(\mathbf{x})$  就是 MVU 估计量，开口  $I(\theta)$  就是精度
9. WGN 中：CRLB = 噪声功率  $\div$  信号对参数的敏感度能量， $s''$  被期望抹掉
10. 换参数：界乘  $(g')^2$ ，但最优性不跟着搬家