

ECG 762 · DETECTION & ESTIMATION THEORY

覆盖范围: Kay, *Fundamentals of Statistical Signal Processing, Vol. I: Estimation Theory*

第 2 章 (MVU 估计) ~ 3.6 节 (参数变换)

整理: Chang Wang · **课程:** ECG 762 · **整理日期:** 2026-09-14

0. 全景地图：这几节在讲一条什么样的逻辑链

先把主线拎出来，后面所有细节都挂在这条链上：

怎么衡量一个估计量的好坏？ → $mse = var + bias^2$ (2.6)
↓ 直接最小化 mse 做不到（最优解依赖未知的 θ ）
先强制无偏，再最小化方差 → MVU 估计量
↓ MVU 存在吗？找得到吗？
先问：无偏估计量最好能做到多好？ → $CRLB \quad var(\hat{\theta}) \geq 1/I(\theta)$ (3.6)
↓ $I(\theta)$ 怎么算？
Fisher 信息 = 对数似然的平均曲率 → $I(\theta) = -E[\partial^2 \ln p / \partial \theta^2]$
↓ 界什么时候够得着？够得着时估计量是谁？
可达条件（分解 score） → $\partial \ln p / \partial \theta = I(\theta)(g(x) - \theta)$ (3.7)
↓ 具体到"WGN 中的信号"这一大类模型
通用公式 → $var(\hat{\theta}) \geq \sigma^2 / \Sigma(\partial s / \partial \theta)^2$ (3.14)
↓ 我关心的不是 θ 而是 $g(\theta)$ 怎么办？
参数变换 → $var(\alpha) \geq (\partial g / \partial \theta)^2 / I(\theta)$ (3.16)

一句话总结这几节：在动手设计算法之前，先在纸上算出"理论上最好能多准"，并且顺便看看那个最优估计量会不会自己掉出来。

1. 前置知识：从 MSE 到 MVU（第 2 章）

1.1 无偏 $\neq$ 好

无偏只保证"平均而言能命中真值"，不保证单次估计准。但无偏性在合并多个估计时至关重要。

1.2 平均 n 个估计量：方差为什么是 $var(\theta_i)/n$

设 $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n \hat{\theta}_i$ ，两个假设各用在一步：

第一步（用"互不相关"）

方差的两条基本性质：

- 常数提出要平方： $var(aX) = a^2 var(X)$ ，这里 $a = 1/n$ ，提出来是 $1/n^2$ 而非 $1/n$
- 和的方差： $var(\sum_i \hat{\theta}_i) = \sum_i var(\hat{\theta}_i) + 2 \sum_{i < j} cov(\hat{\theta}_i, \hat{\theta}_j)$

uncorrelated 让所有协方差为零，交叉项整块消失：

$$var(\hat{\theta}) = \frac{1}{n^2} \sum_{i=1}^n var(\hat{\theta}_i)$$

⚠ 若各估计相关（例如来自同一批数据、共用同一噪声源），交叉项不为零，结论失效。极端情况：所有 $\hat{\theta}_i$ 完全相同时，平均后方差一点也没降。

第二步（用"同方差"）

$\text{var}(\hat{\theta}_i) \equiv \sigma^2$ 对所有 i 成立，于是求和是 n 个相同的数相加：

$$\text{var}(\hat{\theta}) = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n} = \frac{\text{var}(\hat{\theta}_1)}{n}$$

✳ 这里的 $\hat{\theta}_1$ 没有任何特殊性，只是"随便拿一个当代表"来指代那个公共的 σ^2 。写成 $\text{var}(\hat{\theta}_1)/n$ 完全等价。

直觉： $1/n^2$ 与 n 项相加，一个平方、一个线性，净剩 $1/n$ ；标准差按 $1/\sqrt{n}$ 下降。随机误差每次方向不同，相加时互相抵消（**非相干叠加**）。

而偏差不会被抵消： 若 $E(\hat{\theta}_i) = \theta + b$ ，则 $E(\hat{\theta}) = \theta + b$ 。偏差每次朝同一方向偏，是**相干叠加**： n 个 b 加起来是 nb ，除以 n 又变回 b 。

核心结论： 平均（或增加数据）能压方差，压不掉偏差。

1.3 图 2.2 怎么读

视觉现象	含义	(a) 无偏	(b) 有偏
峰变高变窄（纵向）	方差 σ^2/n 减小；密度积分恒为 1，变窄必然变高	✓ 有	✓ 有
峰偏离 θ （横向）	偏差 b	✗ 无	✓ 有，且不随 n 缩小

- (a)：越来越准地锁定真值
- (b)：越来越**自信地锁定一个错值**—— n 增大反而使你对偏离真值的结果更加确信，情况更糟

1.4 MSE 分解： $\text{mse} = \text{var} + \text{bias}^2$ （式 2.6）

配凑技巧： 在括号里同时加减 $E(\hat{\theta})$ ：

$$\hat{\theta} - \theta = \underbrace{(\hat{\theta} - E(\hat{\theta}))}_A + \underbrace{(E(\hat{\theta}) - \theta)}_B$$

两部分性质完全不同：

- A 是**随机量**（围绕自身均值的抖动）， $E[A] = 0$
- B 是**确定常数**（ $E(\hat{\theta})$ 和 θ 都是固定数值），即偏差 $b(\theta)$

展开：

$$E[(A+B)^2] = \underbrace{E[A^2]}_{=\text{var}(\hat{\theta})} + \underbrace{2E[AB]}_{=2B \cdot E[A]=0} + \underbrace{E[B^2]}_{=b^2(\theta)}$$

交叉项为零的关键： B 是常数可提到期望外，而 $E[A] = 0$ 。

$$\text{mse}(\hat{\theta}) = \text{var}(\hat{\theta}) + b^2(\theta)$$

几何上等价于勾股定理：零均值随机分量 A 与常数分量 B 在 L^2 空间中正交，所以是平方相加、无交叉项。

1.5 为什么转向 MVU

$b(\theta)$ 依赖未知的 θ ，所以直接最小化 mse 通常做不到（最优估计量会依赖你正在找的那个量）。因此教材转而：先强制 $b = 0$ （限定无偏），再最小化方差 $\rightarrow$ MVU 估计量。

1.6 图 2.5 怎么读

- 虚线是 CRLB，是 θ 的函数（不同真值处难度不同），所有实线（各无偏估计量的方差）都在其上方
- $\hat{\theta}_2$ 与 $\hat{\theta}_3$ 相交 $\Rightarrow$ 各有擅长区间，谁也不是一致最优。这是为什么 MVU 要求在每一个 θ 上都最小 ("for each value of θ ")
- $\hat{\theta}_1$ 处处最低但没贴到虚线：下界达不到 $\neq$ MVU 不存在。此时 CRLB 这条路走不通，需改用 RBLS 定理（第 5 章）

2. 似然函数：定义与计算

2.1 一个函数，两种读法

似然函数和 PDF 是同一个函数 $p(\mathbf{x}; \theta)$ ，只是"把谁当变量"反过来了。

	固定什么	变量	问的问题
PDF	参数 θ	数据 $\mathbf{x}$	参数是 θ 时，各种数据出现的可能性分布？
似然函数	数据 $\mathbf{x}$ （已观测到）	参数 θ	我手上这组数据，在各候选 θ 下有多"像话"？

估计问题里数据已知、 θ 未知，所以要反过来看。似然函数本质上是给每个候选 θ 打分。

2.2 计算三步

1. 写出数据的 PDF（由信号+噪声模型决定）
2. 把实际观测到的数字代进去
3. 剩下的、只含 θ 的表达式就是 $L(\theta)$

2.3 例子

离散（最直观）：抛 10 次得 7 正， $L(p) = \binom{10}{7} p^7 (1-p)^3$ 。 $L(0.5) = 0.117$, $L(0.7) = 0.267$, $L(0.2) = 0.0008 \Rightarrow p = 0.7$ 最能解释数据，即 MLE。

连续（Example 3.1）： $x[0] = A + w[0]$, $w[0] \sim \mathcal{N}(0, \sigma^2)$, 代入观测值 $x[0] = 3$ ：

$$L(A) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left[-\frac{1}{2\sigma^2}(3-A)^2\right]$$

这就是图 3.1 画的曲线——横轴是 A ，不是 x 。

2.4 多样本与对数似然

独立时联合 PDF 连乘，取对数变连加：

$$\ln p(\mathbf{x}; A) = -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A)^2$$

高斯情形下这是 A 的二次函数（开口向下的抛物线），求导一次即可解出峰值。

2.5 三个常见误区

✗ 错误理解	✓ 正确理解
似乎是 θ 的概率	$\int L(\theta) d\theta \neq 1$ ，连续情形是密度值可 >1 。只有相对大小有意义，常数因子可随便扔
$p(\mathbf{x}; \theta)$ 与 $p(\mathbf{x} \theta)$ 一样	分号表示 θ 是确定但未知的常数（经典/频率派）；竖线是贝叶斯的条件概率， θ 也是随机变量并配先验（第 10 章起）
图 3.1 横轴是 x	横轴是候选参数值 A

3. 估计精度从哪里来（3.3 节）

Kay 用同一个例子给了三个层次的解释。

3.1 第一层：误差就是噪声本身

单样本 $x[0] = A + w[0]$ ，取 $\hat{A} = x[0]$ ：

$$E[\hat{A}] = A \text{（无偏）}, \quad \text{var}(\hat{A}) = \sigma^2, \quad \hat{A} - A = w[0]$$

只有一个样本，没有"平均掉噪声"的余地，这次测量偏多少，估计就偏多少。所以"精度"和"噪声强度"在这里是同一个数。

3.2 第二层：似然函数的"尖锐度"（图 3.1）

固定 $x[0] = 3$ ，把 $p(x[0]; A)$ 画成 A 的函数：

σ	曲线形状	关键数值	可信区间 $3 \pm 3\sigma$
$\sigma_1 = 1/3$	又高又尖	$p_1(3; A=4)\delta = 0.01\delta$ vs $p_1(3; A=3)\delta = 1.20\delta$, 相差约 120 倍	[2, 4]
$\sigma_2 = 1$	又矮又胖	$A = 2, 3, 4, 5$ 的似然差不多, 无法分辨	[0, 6]

机制： σ^2 小 $\Rightarrow$ PDF 对 A 依赖强 $\Rightarrow$ 一次观测能排除更多候选值 $\Rightarrow$ 信息量大。

这正是 3.3 节开头的纲领："the more the PDF is influenced by the unknown parameter, the better we should be able to estimate it."

💡 细节：高斯 PDF 只通过差值 $(x[0] - A)$ 依赖两者，所以同一个 σ 同时扮演两个角色——既是 x 围绕 A 的散布，也是似然沿 A 轴的宽度。这解释了为什么第一层和第二层是同一个数。

3.3 第三层：曲率 = Fisher 信息（式 3.3）

$$-\frac{\partial^2 \ln p(x[0]; A)}{\partial A^2} = \frac{1}{\sigma^2} = I(A) \implies \text{var}(\hat{A}) = \sigma^2 = \frac{1}{I(A)}$$

模糊的"accuracy improves"被精确化成 $\text{CRLB} = \sigma^2$ ，且 $\hat{A} = x[0]$ 正好达到它。

3.4 极限检验

极限	似然函数形态	曲率	CRLB
$\sigma^2 \rightarrow 0$	退化成 $A = x[0]$ 处的冲激	$\rightarrow \infty$	$\rightarrow 0$, 完美估计
$\sigma^2 \rightarrow \infty$	沿 A 方向趋于平坦 (PDF 不依赖参数)	$\rightarrow 0$	$\rightarrow \infty$, 无信息可提取

4. CRLB 定理（3.4 节，Theorem 3.1）

4.1 定理陈述

正则条件： $E \left[\frac{\partial \ln p(\mathbf{x}; \theta)}{\partial \theta} \right] = 0$ for all θ

下界：

$$\text{var}(\hat{\theta}) \geq \frac{1}{-E \left[\frac{\partial^2 \ln p(\mathbf{x}; \theta)}{\partial \theta^2} \right]} = \frac{1}{I(\theta)} \tag{3.6}$$

可达条件（当且仅当）：

$$\frac{\partial \ln p(\mathbf{x}; \theta)}{\partial \theta} = I(\theta)(g(\mathbf{x}) - \theta) \quad (3.7)$$

此时 $\hat{\theta} = g(\mathbf{x})$ 即 MVU 估计量，最小方差为 $1/I(\theta)$ 。

4.2 $\ln$ 是从哪来的？（完整推导）

$\ln$ 不是为了方便才取的，它是从推导里自动长出来的。

从无偏条件出发：

$$\int \hat{\theta}(\mathbf{x}) p(\mathbf{x}; \theta) d\mathbf{x} = \theta$$

两边对 θ 求导（ $\hat{\theta}(\mathbf{x})$ 不含 θ ）：

$$\int \hat{\theta}(\mathbf{x}) \frac{\partial p}{\partial \theta} d\mathbf{x} = 1$$

问题：左边不是一个期望（期望必须是“某量 $\times p$ 再积分”）。为了凑出 p ，用恒等式：

$$\frac{\partial p}{\partial \theta} = p \cdot \frac{1}{p} \frac{\partial p}{\partial \theta} = p \cdot \frac{\partial \ln p}{\partial \theta}$$

← $\ln$ 就是从这里来的。取对数的作用是：把“密度的绝对变化率”换成“相对变化率”，从而自动带出权重 p 。

于是 $E[\hat{\theta}s] = 1$ ，其中 $s \triangleq \frac{\partial \ln p}{\partial \theta}$ 称为 **score**（得分函数）。

4.3 正则条件的来历

同样的技巧用在 $\int p d\mathbf{x} = 1$ 上：

$$E[s] = \int \frac{\partial \ln p}{\partial \theta} p d\mathbf{x} = \int \frac{\partial p}{\partial \theta} d\mathbf{x} = \frac{\partial}{\partial \theta} \int p d\mathbf{x} = \frac{\partial(1)}{\partial \theta} = 0$$

所以正则条件本质上是“求导与积分可交换”的技术要求。

4.4 用 Cauchy-Schwarz 收尾

由 $E[s] = 0$ 得 $\text{cov}(\hat{\theta}, s) = E[\hat{\theta}s] - E[\hat{\theta}]E[s] = 1$ 。再由 $\text{cov}^2(X, Y) \leq \text{var}(X)\text{var}(Y)$ ：

$$1 \leq \text{var}(\hat{\theta}) \cdot \underbrace{\text{var}(s)}_{=I(\theta)} \implies \text{var}(\hat{\theta}) \geq \frac{1}{I(\theta)}$$

Cauchy-Schwarz 取等号的条件是 $\hat{\theta} - \theta$ 与 s 成比例——这正是可达条件 (3.7) 的来源。

4.5 与 MLE 的关系

同一个对数似然，两种用法：

	操作	性质
MLE	令 $s = 0$, 解出 $\hat{\theta}$	对具体一组数据操作, 结果是随机的
CRLB	对 s 平方再求期望 (对所有可能数据平均)	确定的函数, 描述模型平均能提供多少信息

深层联系: MLE 是渐近有效的—— $N \rightarrow \infty$ 时 MLE 渐近无偏且方差趋于 CRLB (第 7 章)。

5. Fisher 信息：怎么算、为什么能提前算

5.1 三步配方

$$I(\theta) = -E \left[\frac{\partial^2 \ln p(\mathbf{x}; \theta)}{\partial \theta^2} \right]$$

1. 写出 $\ln p(\mathbf{x}; \theta)$
2. 对 θ 求两次导
3. 取期望——用模型已知的矩 (如 $E[w[n]] = 0$ 、 $E[w^2[n]] = \sigma^2$), 再加负号

5.2 三类例子 (按难度递增)

例 A: 二阶导里根本没有 $\mathbf{x}$ (最省事) — Example 3.3

$$\frac{\partial \ln p}{\partial A} = \frac{1}{\sigma^2} \sum_n (x[n] - A) = \frac{N}{\sigma^2} (\bar{x} - A), \quad \frac{\partial^2 \ln p}{\partial A^2} = -\frac{N}{\sigma^2}$$

二阶导是常数, $\mathbf{x}$ 全消失, 期望免费: $I(A) = N/\sigma^2$ 。 (同时一阶导已是 (3.7) 形式, $g(\mathbf{x}) = \bar{x} \Rightarrow$ 样本均值是 MVU, $\text{var} = \sigma^2/N$ 。)

例 B: 含 $\mathbf{x}$, 但被零均值噪声消掉 (最典型) — 通式 (3.14)

见第 7 节详细推导。关键: $E[x[n] - s[n; \theta]] = E[w[n]] = 0$, 含数据的那一整项归零。

例 C: 需要用到二阶矩 — Example 3.6 估计 σ^2

$$\frac{\partial^2 \ln p}{\partial (\sigma^2)^2} = \frac{N}{2\sigma^4} - \frac{1}{\sigma^6} \sum_n (x[n] - A)^2$$

用 $E[(x[n] - A)^2] = \sigma^2$:

$$E[\cdot] = \frac{N}{2\sigma^4} - \frac{N\sigma^2}{\sigma^6} = -\frac{N}{2\sigma^4} \Rightarrow I(\sigma^2) = \frac{N}{2\sigma^4}, \quad \text{var}(\widehat{\sigma^2}) \geq \frac{2\sigma^4}{N}$$

5.3 两个等价公式, 用哪个?

$$I(\theta) = E \left[\left(\frac{\partial \ln p}{\partial \theta} \right)^2 \right] = -E \left[\frac{\partial^2 \ln p}{\partial \theta^2} \right] \tag{3.23}$$

实践中几乎总用二阶导版本——二阶导常常不含 $\mathbf{x}$ (如例 A)，期望白送；一阶导平方总要展开算矩，麻烦得多。

5.4 为什么能"提前"算出来 ★

这是最关键的概念问题。答案在于期望符号把数据积分掉了：

$$I(\theta) = - \int \frac{\partial^2 \ln p(\mathbf{x}; \theta)}{\partial \theta^2} p(\mathbf{x}; \theta) d\mathbf{x}$$

$\partial^2 \ln p / \partial \theta^2$ 确实是随机变量，但 $\int (\cdot) p d\mathbf{x}$ 对所有可能出现的数据集做了加权平均，算完 $\mathbf{x}$ 已不在结果里，只剩 θ 和模型参数 (σ^2 、 N)。

它是"模型的属性"，不是"某次实验的属性"。类比：你不用真的掷骰子，就能算出均匀骰子点数的方差是 35/12——因为你知道它的概率模型。

物理含义可以这样念：

"如果真值是 θ ，那么在它会产生所有可能数据集上，对数似然的平均曲率是多少。"

注意 θ 没有被积掉，它作为自由变量留在答案里。所以得到的是一条函数曲线 $I(\theta)$ ——你一次性把"真值取遍所有可能"的情形都算完了。这正是图 2.5 的虚线、图 3.3 的起伏曲线的由来。

5.5 可加性

独立样本的 Fisher 信息可加： $I_N(\theta) = N \cdot I_1(\theta)$ (因为 $\ln p$ 是连加，求导和期望都保持可加)。这既是计算捷径，也解释了 CRLB 中 $1/N$ 因子的来源：每多一个独立样本，就多贡献一份等量的信息。

6. 可达条件与有效估计量

6.1 (3.7) 的几何图像：对数似然是一条抛物线 ★

把 score 看成 θ 的函数：

$$s(\theta) = I(\theta)(g(\mathbf{x}) - \theta)$$

这是一条直线，斜率 $-I(\theta)$ ，过零点在 $\theta = g(\mathbf{x})$ 。导数是直线 $\Rightarrow$ 对数似然本身是抛物线：

$$\ln p(\mathbf{x}; \theta) = \text{const}(\mathbf{x}) - \frac{I}{2}(\theta - g(\mathbf{x}))^2$$

于是全部含义都清楚了：

元素	含义
$g(\mathbf{x})$	抛物线顶点的位置。数据变了，整条抛物线左右平移，顶点跟着数据走
$I(\theta)$	抛物线的开口（曲率），不随数据变 $\Rightarrow$ 精度固定、事先可知
数据的作用	只负责"指定顶点位置"，其余形状不变

(3.7) 的苛刻之处： θ 只能以"孤零零被减掉"的方式出现，外面再乘一个纯 θ 的系数。数据和参数必须干净地分离。

6.2 $g(\mathbf{x})$ 到底是什么

它就是把 score 因式分解后剩下的那个"只含数据、不含 θ "的函数。不是你事先挑的，而是算出来的。

$\hat{\theta} = g(\mathbf{x})$ 这一步是定义/选择，不是推导出来的——定理在宣布"把估计量取成这个函数"。定理的实质内容是：这样取出来的估计量恰好无偏、且方差正好等于 $1/I(\theta)$ 。

为什么这是唯一合理的选择？三个角度：

1. 抛物线顶点：令 $\text{score} = 0$ (MLE) $\Rightarrow \theta = g(\mathbf{x})$ 。数据唯一"指认"出来的那个 θ 值
2. 零点应在真值附近：正则条件说在真值处 $E[s] = 0$ ，而 $g(\mathbf{x})$ 正是本次数据给出的零点
3. Cauchy-Schwarz 等号条件：要求 $\hat{\theta} - \theta = \frac{1}{I(\theta)}s$ ，对照可知 $\hat{\theta}$ 只能是 $g(\mathbf{x})$

✦ $g(\mathbf{x})$ 不含 θ 是关键——这才使它能当估计量用。含 θ 的表达式你算不出来。✦ MVU 估计量（在几乎处处意义下）唯一，所以不存在"另一个也能达到下界的估计量"。

6.3 三个"白送"的性质

从 (3.7) 出发，三件事不用另外验证：

① 一定无偏。由 $E[s] = 0$ ：

$$0 = E[I(\theta)(g - \theta)] = I(\theta)(E[g] - \theta) \Rightarrow E[g(\mathbf{x})] = \theta$$

② 分解出的乘子就是 Fisher 信息。设分解为 $s = c(\theta)(g - \theta)$ ，则

$$-E\left[\frac{\partial s}{\partial \theta}\right] = -E[c'(\theta)(g - \theta) - c(\theta)] = -c'(\theta)\underbrace{E[g - \theta]}_{=0} + c(\theta) = c(\theta)$$

所以不需要事先知道 $I(\theta)$ ，随手分解出的系数就是它。

③ 方差正好等于下界： $\text{var}(s) = I(\theta)$ 且 $\text{var}(s) = I^2(\theta)\text{var}(g) \Rightarrow \text{var}(g) = 1/I(\theta)$ 。

无偏 + 方差达到 CRLB $\Rightarrow$ 它就是 MVU。这就是"CRLB 理论顺带把估计量给出来"的意思。

6.4 式 (3.10) 那半页证明在干什么

它在补一个记号上的漏洞：定理 3.1 说 (3.7) 中的 I 只是 "some function"，凭什么它就等于 $-E[\partial^2 \ln p / \partial \theta^2]$ ？上面 ② 就是答案（书上用 $\hat{\theta}$ 代替 $g(\mathbf{x})$ 走了一遍）。

两个关键点：

- $\hat{\theta} = g(\mathbf{x})$ 不含 θ ，所以 $\partial \hat{\theta} / \partial \theta = 0$ ，乘积法则只出两项
- 无偏性杀掉了 $I'(\theta)$ 那一项，哪怕 $I(\theta)$ 随 θ 变化也无妨

实用价值：若 (3.7) 能配出来，不必再算二阶导和期望，直接读系数。Example 3.3 一次求导即同时拿到估计量、Fisher 信息、最小方差，并已证明是 MVU。

6.5 配不出来怎么办

若 θ 缠在数据里出不来（如 Example 3.4 相位估计、Example 3.5 频率估计），则有效估计量不存在。此时：

- CRLB 仍可算，作为性能基准
- 找 MVU 需转第 5 章 RBLS 定理（充分统计量）
- 或退而求其次：第 6 章 BLUE（限定线性）、第 7 章 MLE（渐近有效）

7. WGN 中信号的通用 CRLB (3.5 节)

7.1 模型与推导

$$x[n] = s[n; \theta] + w[n], \quad w[n] \sim \text{WGN}(0, \sigma^2), \quad n = 0, \dots, N-1$$

记 $s'[n] \triangleq \partial s[n; \theta] / \partial \theta$ ， $s''[n] \triangleq \partial^2 s[n; \theta] / \partial \theta^2$ 。

一阶导（链式法则，内导数带负号，两个负号相消）：

$$\frac{\partial \ln p}{\partial \theta} = \frac{1}{\sigma^2} \sum_{n=0}^{N-1} (x[n] - s[n; \theta]) s'[n]$$

二阶导（乘积法则，两个因子都含 θ ）：

$$\begin{aligned} \frac{\partial}{\partial \theta} [(x[n] - s) s'] &= \underbrace{(-s') \cdot s'}_{\text{第一因子求导}} + \underbrace{(x[n] - s) \cdot s''}_{\text{第二因子求导}} \\ \frac{\partial^2 \ln p}{\partial \theta^2} &= \frac{1}{\sigma^2} \sum_{n=0}^{N-1} \left\{ (x[n] - s[n; \theta]) s''[n] - (s'[n])^2 \right\} \end{aligned}$$

7.2 取期望：为什么结果只剩信号 ★

先分清谁是随机的：

量	随机吗	理由
$x[n]$	是	含噪声
$s[n; \theta]$ 、 $s'[n]$ 、 $s''[n]$	否	已知信号模型及其导数，只是 n, θ 的确定函数
σ^2, N	否	模型参数

整个二阶导里唯一的随机成分是 $x[n]$ ，且以一次方（线性）出现——这意味着只需噪声的一阶矩。

第一项： $s''[n]$ 确定可提出，而

$$x[n] - s[n; \theta] = w[n] \implies E[x[n] - s[n; \theta]] = E[w[n]] = 0$$

$\implies$ 整块归零， s'' 无论多复杂都无所谓。

第二项： $(s'[n])^2$ 完全确定，期望就是自身。

$$E \left[\frac{\partial^2 \ln p}{\partial \theta^2} \right] = -\frac{1}{\sigma^2} \sum_{n=0}^{N-1} (s'[n])^2$$

$$\boxed{\text{var}(\hat{\theta}) \geq \frac{\sigma^2}{\sum_{n=0}^{N-1} \left(\frac{\partial s[n; \theta]}{\partial \theta} \right)^2}} \quad (3.14)$$

7.3 ⚠ 关键细节：为什么 $x[n] - s[n; \theta]$ 恰好是噪声

这依赖定理 3.1 里一句容易被略过的话：

*"the derivative is evaluated at the **true value of θ** and the expectation is taken with respect to $p(\mathbf{x}; \theta)$ "*

两处的 θ 是同一个值。求导后代入的 θ 是真值，取期望时数据分布也由这同一个真值产生，于是 $E_\theta[x[n]] = s[n; \theta]$ ，残差正好是纯噪声。

若代入 $\theta' \neq \theta$ ：

$$x[n] - s[n; \theta'] = \underbrace{s[n; \theta] - s[n; \theta']}_{\neq 0, \text{确定性偏差}} + w[n]$$

均值不为零，第一项不会消失，(3.14) 也就不成立。

所以"在真值处求值"不是可有可无的措辞，而是这步化简的前提。这也解释了 CRLB 为什么是 θ 的函数：每个候选真值对应一次独立的计算。

7.4 交叉验证：换一条路算

用 $I(\theta) = E[(\partial \ln p / \partial \theta)^2]$ ，把一阶导写成噪声形式 $\frac{1}{\sigma^2} \sum_n w[n] s'[n]$ ：

I(theta) = 1/sigma^4 sum_n sum_m s'[n] s'[m] E[w[n] w[m]] = 1/sigma^2 sum_n (s'[n])^2

两条路径用到的假设不同，很有启发：

路径	用到的噪声假设
二阶导	仅 $E[w[n]] = 0$ （零均值）
一阶导平方	$E[w[n]w[m]] = \sigma^2\delta[n - m]$ （零均值 + 白，交叉项因不相关而消失）

高斯性在更早就用掉了——它决定了 ln p 是二次型。

7.5 结果怎么读：几何图像

var(hat(theta)) >= (噪声功率) / (信号对参数的敏感度能量)

把 s(theta) = [s[0;theta], ..., s[N-1;theta]]^T 看成 R^N 中随 theta 移动的曲线：

- s'(theta) 是切向量，||s'||^2 = sum(s'[n])^2 是曲线的移动速度
- 噪声把观测点模糊成半径约 sigma 的球
- 速度快 => 不同 theta 对应的信号点拉得开 => 噪声球不重叠 => 好估

CRLB = 噪声球半径 ÷ 曲线速度。这就是 Kay 那句 "Signals that change rapidly as the unknown parameter changes result in accurate estimators" 的数学形式。

💡 结构性观察：曲线的弯曲程度 s'' 完全不影响 CRLB，它在平均意义下被噪声抹掉了。但对某一次具体的数据，partial^2 ln p / partial theta^2 里确实还挂着 w[n] s''[n]——观测曲率围绕平均曲率随机起伏，Fisher 信息取的是平均值。这再次说明 E[.] 不是装饰。

7.6 例题速查表

例	参数	s[n; theta]	partial s / partial theta	sum (partial s / partial theta)^2	CRLB
3.3	DC 电平 A	A	1	N	sigma^2 / N
3.4	相位 phi	A cos(2pi f_0 n + phi)	-A sin(2pi f_0 n + phi)	approx N A^2 / 2	2 sigma^2 / (N A^2)
3.5	频率 f_0	A cos(2pi f_0 n + phi)	-2pi n A sin(2pi f_0 n + phi)	A^2 sum [2pi n sin(.)]^2	式 (3.15)
3.6	方差 sigma^2	—	—	—	2 sigma^4 / N
3.7	截距 A (B 未知)	A + B n	1	—	2(2N - 1) sigma^2 / (N(N + 1))
3.7	斜率 B (A 未知)	A + B n	n	—	12 sigma^2 / (N(N^2 - 1))

频率行的 n 因子说明为什么**频率比相位好估得多** ($1/N^3$ vs $1/N$): 时间越靠后的采样点对频率误差越敏感, 相位误差随 n 线性累积。同样的机制解释了 Example 3.7 里斜率 B 比截距 A 好估。

Example 3.7 还给出一条通则: **估计的参数越多, CRLB 越大** (A 的界从 σ^2/N 涨到 $\frac{2(2N-1)\sigma^2}{N(N+1)}$)。

8. Example 3.4 完整拆解 (相位估计)

这是全章代数最繁的一例, 专门列出。

8.1 记号

$$\alpha_n \triangleq 2\pi f_0 n + \phi, \quad \frac{\partial \alpha_n}{\partial \phi} = 1, \quad 4\pi f_0 n + 2\phi = 2\alpha_n$$

8.2 求导公式表 (注意内导数)

式子	对 ϕ 求导	内导数
$\cos \alpha_n$	$-\sin \alpha_n$	1
$\sin \alpha_n$	$\cos \alpha_n$	1
$\sin 2\alpha_n$	$2 \cos 2\alpha_n$	2
$\cos 2\alpha_n$	$-2 \sin 2\alpha_n$	2

⚠ 那个 2 是后面所有系数对得上的关键, 漏了就全错。

8.3 三角恒等式: 两条, 都是积化和差的特例

$$\sin A \cos B = \frac{1}{2} [\sin(A+B) + \sin(A-B)] \xrightarrow{A=B=\alpha} \boxed{\sin \alpha \cos \alpha = \frac{1}{2} \sin 2\alpha} \quad (\text{二倍角})$$

$$\cos A \cos B = \frac{1}{2} [\cos(A+B) + \cos(A-B)] \xrightarrow{A=B=\alpha} \boxed{\cos^2 \alpha = \frac{1}{2} + \frac{1}{2} \cos 2\alpha} \quad (\text{降幂})$$

"积化和差"和"二倍角"在这里是同一条公式的两次使用: 把两个正弦量的乘积拆成"直流项 + 二倍频项"。这是整个推导的物理主线。

8.4 六步推导

① **一阶导** (链式法则, $-A \cdot (-\sin \alpha_n) = +A \sin \alpha_n$, 系数 2 与 $\frac{1}{2\sigma^2}$ 约掉):

$$\frac{\partial \ln p}{\partial \phi} = -\frac{1}{\sigma^2} \sum_n [x[n] - A \cos \alpha_n] A \sin \alpha_n$$

② **展开 + 二倍角** (信号自乘产生二倍频分量):

$$= -\frac{A}{\sigma^2} \sum_n \left[x[n] \sin \alpha_n - \frac{A}{2} \sin 2\alpha_n \right]$$

③ 二阶导 ($\frac{1}{2}$ 被内导数的 2 吃掉, 所以系数是干净的 A):

$$\frac{\partial^2 \ln p}{\partial \phi^2} = -\frac{A}{\sigma^2} \sum_n [x[n] \cos \alpha_n - A \cos 2\alpha_n]$$

④ 取负期望 ($E[x[n]] = A \cos \alpha_n$, 平方项出现):

$$-E \left[\frac{\partial^2 \ln p}{\partial \phi^2} \right] = \frac{A}{\sigma^2} \sum_n [A \cos^2 \alpha_n - A \cos 2\alpha_n]$$

⑤ 降幂公式:

$$= \frac{A^2}{\sigma^2} \sum_n \left[\underbrace{\frac{1}{2}}_{\text{直流}} + \frac{1}{2} \cos 2\alpha_n - \cos 2\alpha_n \right] = \frac{A^2}{\sigma^2} \left[\frac{N}{2} - \frac{1}{2} \sum_n \cos(4\pi f_0 n + 2\phi) \right]$$

到这里完全精确, 没有任何近似。

⑥ 二倍频项的抵消 (唯一的近似):

由几何级数求和 (Dirichlet 核):

$$\left| \sum_{n=0}^{N-1} \cos(4\pi f_0 n + 2\phi) \right| = \left| \frac{\sin(2\pi f_0 N)}{\sin(2\pi f_0)} \right| \leq \frac{1}{|\sin(2\pi f_0)|}$$

右边与 N 无关, 是有界常数, 除以 N 后趋于 0。

直觉: 余弦累加很多个周期, 正负半周互相抵消, 只剩末尾不满一周期的零头 ($O(1)$), 而直流项累积成 $O(N)$ 。

$$I(\phi) \approx \frac{NA^2}{2\sigma^2} \implies \boxed{\text{var}(\hat{\phi}) \geq \frac{2\sigma^2}{NA^2} = \frac{1}{N\eta}}, \quad \eta \triangleq \frac{A^2}{2\sigma^2} \text{ (SNR)}$$

相位估计精度只取决于总信噪比 $N\eta$, 与频率 f_0 无关 (只要不在 0 或 $1/2$ 附近)。

8.5 为什么要求 f_0 不接近 0 或 $1/2$

因为分母 $\sin(2\pi f_0)$ 在这两处为零。此时 $2f_0$ 落在整数倍频, $\cos(4\pi f_0 n + 2\phi)$ 退化成常数, 不振荡、不抵消。

取 $f_0 \rightarrow 0$ 精确计算:

$$I(\phi) = \frac{A^2}{\sigma^2} \cdot \frac{N}{2} (1 - \cos 2\phi) = \frac{NA^2 \sin^2 \phi}{\sigma^2}$$

在 $\phi = 0$ 处 $I = 0$, CRLB 发散——**相位完全不可估**。物理上合理: $f_0 = 0$ 时信号是常数 $A \cos \phi$, 而 $\phi = 0$ 恰是余弦极值点, ϕ 的一阶扰动不改变信号。

8.6 捷径: 用 (3.14) 三行搞定

$$s[n; \phi] = A \cos \alpha_n \implies \frac{\partial s}{\partial \phi} = -A \sin \alpha_n \implies I(\phi) = \frac{A^2}{\sigma^2} \sum_n \sin^2 \alpha_n \approx \frac{A^2}{\sigma^2} \cdot \frac{N}{2}$$

(用了 $\overline{\sin^2} = 1/2$, 还是同一条降幂公式。) (3.14) 已经把"期望消掉含数据项"这一步一次性做完了。

8.7 这个例子的真正用意

看 ② 式的 score: ϕ 被锁在 $\sin(\cdot)$ 里面, 与数据 $x[n]$ 缠在一起, 无论如何配不成 $I(\phi)(g(\mathbf{x}) - \phi)$ 。

$\Rightarrow$ 按定理 3.1 的"当且仅当": 有效估计量不存在, CRLB 够不着。这就是 Kay 预告的 "the CRLB is not always satisfied", 对应图 2.5 里 $\hat{\theta}_1$ 贴不到虚线的情形。

9. 参数变换 (3.6 节)

9.1 这一节在干什么

- 3.5: 在具体模型下怎么把 CRLB 算出来
- 3.6: CRLB 已算好, 但你真正想估的不是模型里那个参数, 而是它的某个函数——界怎么换算, 代价是什么

它不是新的推导方法, 而是一个换算规则 + 一条警告。

9.2 动机: 模型参数 $\neq$ 你关心的量

模型 $x[n] = A + w[n]$ 里天然出现的是 A , 但实际可能关心:

- 信号功率 A^2 (雷达回波强度)
- 分贝值 $20 \log_{10} |A|$
- 阵列测向中模型参数是空间频率 $u = \sin \theta$, 你要的是角度 θ
- 模型参数是 σ^2 , 你要标准差 σ

难道每换一个关心的量就要重写似然、重新求二阶导? 3.6 说: 不用。

9.3 规则 (3.16): 就是误差传播公式

若 $\alpha = g(\theta)$:

$$\text{var}(\hat{\alpha}) \geq \frac{(\partial g / \partial \theta)^2}{I(\theta)} = \left(\frac{\partial g}{\partial \theta} \right)^2 \cdot \text{CRLB}(\theta) \quad (3.16)$$

Fisher 信息只算一次 (在最方便的参数化下), 换算时乘一个 $(g')^2$ 。

本质就是一阶误差传播: $\delta \alpha \approx g'(\theta) \delta \theta$, 两边平方取期望, 方差乘 $(g')^2$ 。

生活化类比: 卡尺测半径精度 ± 0.1 mm, 问圆面积精度? $S = \pi r^2$, $dS/dr = 2\pi r$, 所以 $\sigma_S = 2\pi r \cdot 0.1$ 。不需要重新标定一把"测面积的尺子"。

书上的例子: $I(A) = N/\sigma^2$, $g(A) = A^2$, $g' = 2A$:

$$\text{var}(\widehat{A^2}) \geq \frac{(2A)^2}{N/\sigma^2} = \frac{4A^2\sigma^2}{N} \quad (3.17)$$

★ 注意结果里出现的是原参数 A ("the CRLB is expressed in terms of θ "). 必然如此, 因为 Fisher 信息本来就是关于 θ 定义的。

9.4 代价: 非线性变换毁掉有效性 ⚠

$\bar{x}$ 对 A 是有效估计量。那么估 A^2 时直接代入, 用 $\bar{x}^2$ 行不行?

不行——它连无偏都不是:

$$E[\bar{x}^2] = E^2[\bar{x}] + \text{var}(\bar{x}) = A^2 + \frac{\sigma^2}{N} \neq A^2 \quad (3.18)$$

偏差从哪来? 二阶 Taylor 展开一目了然:

$$g(\bar{x}) \approx g(A) + g'(A)(\bar{x} - A) + \frac{1}{2}g''(A)(\bar{x} - A)^2$$

取期望, 一阶项因无偏而消失:

$$E[g(\bar{x})] \approx g(A) + \underbrace{\frac{1}{2}g''(A)\text{var}(\bar{x})}_{\text{偏差}}$$

代入 $g'' = 2$ 、 $\text{var}(\bar{x}) = \sigma^2/N$, 正好得到 σ^2/N ✓

根源是 g 的弯曲 ($g'' \neq 0$): 估计值在真值两侧随机抖动, 经弯曲函数映射后两侧不再对称抵消, 系统性偏向凸的一边 (Jensen 不等式: g 凸时 $E[g(\hat{\theta})] \geq g(E[\hat{\theta}])$)。线性函数没有弯曲, 不受影响。

即使去偏成 $\bar{x}^2 - \sigma^2/N$, 方差仍是

$$\frac{4A^2\sigma^2}{N} + \frac{2\sigma^4}{N^2} > \underbrace{\frac{4A^2\sigma^2}{N}}_{\text{CRLB}}$$

有效性确实丢了, 不只是无偏性的问题。

9.5 线性 (仿射) 变换则完好无损

$\alpha = a\theta + b$, 取 $\hat{\alpha} = a\hat{\theta} + b$:

- 无偏: $E[a\hat{\theta} + b] = a\theta + b = \alpha$ ✓
- 方差: $\text{var}(a\hat{\theta} + b) = a^2\text{var}(\hat{\theta})$
- CRLB 按 (3.16) 也乘 a^2

两边同步缩放, 等号保持。单位换算、加偏置这类操作是安全的。

9.6 大样本下近似恢复: 统计线性化 (图 3.4)

N 增大 $\Rightarrow \bar{x}$ 的 PDF 集中在 $A \pm 3\sigma/\sqrt{N}$ 的小区间 $\Rightarrow$ 在这小区间内, 再弯的 g 也近似是直的 $\Rightarrow$ 非线性退化为线性, 无偏性与有效性近似恢复:

$$\text{var}(\bar{x}^2) = \frac{4A^2\sigma^2}{N} + \underbrace{\frac{2\sigma^4}{N^2}}_{\text{比第一项快一阶趋于0}} \rightarrow \text{CRLB} \quad (3.19)$$

$\Rightarrow \bar{x}^2$ 是 A^2 的渐近有效估计量。实践中"直接代入"通常可接受，但要知道自己在做近似，且 N 小时它是有偏的。

9.7 小结表

	线性变换 $a\theta + b$	非线性变换 $g(\theta)$
CRLB 换算	$a^2 \cdot \text{CRLB}$	$(g')^2 \cdot \text{CRLB}$ ((3.16), 总成立)
无偏性	保持	破坏, 偏差 $\approx \frac{1}{2}g'' \cdot \text{var}(\hat{\theta})$
有效性	保持	破坏, 但 $N \rightarrow \infty$ 渐近恢复
直接代入 $g(\hat{\theta})$	放心用	小样本当心, 大样本可用

一句话记住 3.6: 界可以用链式法则换算, 但"最优性"不能跟着一起搬家。

9.8 它在全书中的位置

- 通向第 7 章 MLE: MLE 有不变性—— $g(\theta)$ 的 MLE 就是 $g(\hat{\theta}_{\text{MLE}})$, 直接代入即可。3.6 解释了为什么这个性质在有限样本下只是近似、大样本下才严格有效
- 通向 3.7/3.8 向量版: 多参数下 $(g')^2$ 换成 Jacobian 夹逼 $\frac{\partial \mathbf{g}}{\partial \boldsymbol{\theta}} \mathbf{I}^{-1}(\boldsymbol{\theta}) \frac{\partial \mathbf{g}}{\partial \boldsymbol{\theta}}^T$ (式 3.30)

10. 概念澄清：我们提前知道真值吗？★

这是学 CRLB 最关键的一道坎。不知道，但"分析性能"和"做估计"是两件事。

	谁	知道 θ 吗	在干什么
估计	系统/算法 (运行时)	不知道	拿到数据, 算出 $\hat{\theta} = g(\mathbf{x})$
性能分析	工程师 (设计时, 纸上)	假设它是某值	回答"如果真值是 θ , 这套方案能准到什么程度"

运行估计时完全不需要 θ —— $\hat{\theta} = \bar{x}$ 这个公式里没有 θ , 只有数据。这正是要求 $g(\mathbf{x})$ 只含数据的原因。

而 CRLB 是一个条件命题:

"假如真值是 θ , 那么任何无偏估计量的方差不会低于 $1/I(\theta)$ 。"

这是设计阶段在纸上做的推演。这也解释了图 2.5 的虚线为什么画成 θ 的函数——它遍历了所有可能的真值。

类比

游标卡尺说明书写"精度 $\pm 0.02 \text{ mm}$ ":

- 这是**仪器的规格**，厂家不知道你要测什么就标定好了
- 你测未知零件，读数 12.34 mm 。不知道真值，但知道真值大概率在 12.34 ± 0.02 内

CRLB 就是估计问题的"精度规格"， $\hat{\theta}$ 才是"读数"。

那这个规格有什么用？

① **可行性论证（工程上最值钱）** 造任何东西之前就能回答"能不能达标"。如 $\text{var}(\hat{A}) \geq \sigma^2/N$ ：要求标准差 ≤ 0.01 、 $\sigma = 1$ ，立刻得 $N \geq 10^4$ 。如果 CRLB 都达不到指标，方案物理上不可能实现，趁早改设计，别浪费三个月调算法。

② **判断算法还有没有优化空间** 仿真方差是 $1.02\sigma^2/N$ 而 CRLB 是 $\sigma^2/N \Rightarrow$ 收工，没有无偏估计量能更好。若是 CRLB 的 10 倍 $\Rightarrow$ 有信息没榨干。没有 CRLB，你永远不知道该停在哪。

③ **指出"哪里难估、为什么难"** Example 3.5 告诉你低频段本质上难估（不是你算法烂）；Example 3.7 告诉你斜率比截距好估、参数越多界越大。这些直接指导**波形/系统设计**——既然性能取决于 $\sum(\partial s/\partial \theta)^2$ ，就把信号设计成对参数敏感的形状。

④ 顺带给出估计量——(3.7) 的分解。

"CRLB 依赖未知的 θ "怎么办

1. 运气好，根本不依赖。如 σ^2/N 对所有 A 相同（Example 3.2 特意写了 "for all A "）
2. 依赖就画出整条曲线（图 3.3），按工作区间内**最坏情况**设计
3. 把估计值代回去：用 $I(\hat{\theta})^{-1}$ 作为本次测量的**误差棒**。实际系统（雷达、GPS、定位算法）报告的精度基本都这么来的

仿真时你**确实知道真值**（自己生成的），所以能算经验方差验证。真实部署时不知道——正因如此才需要一个**纯靠模型推导、不依赖实测**的性能理论。CRLB 让你省掉"先造出来再看行不行"的昂贵弯路。

11. 常见误区汇总

✖ 误区	✔ 正确
无偏就是好估计量	无偏只保证平均命中；方差大照样烂。看 $mse = var + bias^2$
平均更多估计能消除偏差	只能消方差。偏差是相干叠加， n 个 b 除以 n 还是 b
似然函数是 θ 的概率	不是密度、不积分为 1、可大于 1。只有相对大小有意义
图 3.1 横轴是数据	横轴是候选参数 A
CRLB 达不到 $\Rightarrow$ MVU 不存在	只是充分条件。贴到界上一定是 MVU；贴不上只说明这条路失败（图 2.5 的 $\hat{\theta}_1$ ）
CRLB 对所有估计量成立	只对无偏估计量。有偏估计方差可低于 CRLB（极端例： $\hat{\theta} \equiv 0$ 方差为零），代价是偏差。有偏版本分子要乘 $(1 + \partial b / \partial \theta)^2$
CRLB 需要先测量才能算	期望把数据积分掉了，它是模型的属性。纸上即可算出整条曲线
(3.14) 对任何 θ 值都成立	必须在真值处求值，否则 $x[n] - s[n; \theta']$ 不是零均值，含数据项不消失
有效估计量的 g 可以随便选	g 是因式分解被迫剩下的，且必须不含 θ 。MVU 唯一
估 $g(\theta)$ 直接代入 $g(\hat{\theta})$ 就行	非线性变换破坏无偏与有效（大样本才近似成立）
Fisher 信息越大，估计越差	反了。 I 大 $\Rightarrow$ 似然尖 $\Rightarrow$ 界 $1/I$ 小 $\Rightarrow$ 越准

12. 公式速查表

基础

名称	公式
偏差	$b(\theta) = E(\hat{\theta}) - \theta$
MSE 分解	$mse(\hat{\theta}) = var(\hat{\theta}) + b^2(\theta)$
平均 n 个独立同方差无偏估计	$E(\hat{\theta}) = \theta, \quad var(\hat{\theta}) = var(\hat{\theta}_1)/n$

CRLB 核心

名称	公式
正则条件	$E \left[\frac{\partial \ln p}{\partial \theta} \right] = 0$ for all θ
score	$s = \frac{\partial \ln p(\mathbf{x}; \theta)}{\partial \theta}, \quad E[s] = 0$
Fisher 信息	$I(\theta) = -E \left[\frac{\partial^2 \ln p}{\partial \theta^2} \right] = E \left[\left(\frac{\partial \ln p}{\partial \theta} \right)^2 \right]$
CRLB	$\text{var}(\hat{\theta}) \geq 1/I(\theta)$
可加性	$I_N(\theta) = N \cdot I_1(\theta)$ (独立样本)
可达条件	$\frac{\partial \ln p}{\partial \theta} = I(\theta)(g(\mathbf{x}) - \theta) \Rightarrow \hat{\theta} = g(\mathbf{x})$ 为 MVU
WGN 中信号通式	$\text{var}(\hat{\theta}) \geq \frac{\sigma^2}{\sum_n (\partial s[n; \theta] / \partial \theta)^2}$
参数变换	$\text{var}(\hat{\alpha}) \geq \frac{(\partial g / \partial \theta)^2}{I(\theta)}, \quad \alpha = g(\theta)$
向量版	$\mathbf{C}_{\hat{\theta}} - \mathbf{I}^{-1}(\theta) \geq 0, \quad [\mathbf{I}]_{ij} = -E \left[\frac{\partial^2 \ln p}{\partial \theta_i \partial \theta_j} \right]$

常用数学工具

用途	公式
ln 的来历	$\frac{\partial p}{\partial \theta} = p \cdot \frac{\partial \ln p}{\partial \theta}$
二倍角	$\sin \alpha \cos \alpha = \frac{1}{2} \sin 2\alpha$
降幂	$\cos^2 \alpha = \frac{1}{2} + \frac{1}{2} \cos 2\alpha, \quad \sin^2 \alpha = \frac{1}{2} - \frac{1}{2} \cos 2\alpha$
积化和差	$\sin A \cos B = \frac{1}{2} [\sin(A+B) + \sin(A-B)]; \quad \cos A \cos B = \frac{1}{2} [\cos(A+B) + \cos(A-B)]$
正弦求和 (Dirichlet)	$\left\ \sum_{n=0}^{N-1} \cos(2\pi f n + \psi) \right\ \leq \frac{1}{\ \sin \pi f\ }$ (与 N 无关)
非线性变换偏差	$E[g(\hat{\theta})] \approx g(\theta) + \frac{1}{2} g''(\theta) \text{var}(\hat{\theta})$
高斯四阶矩	$\xi \sim \mathcal{N}(\mu, \sigma^2): \quad E[\xi^2] = \mu^2 + \sigma^2, \quad \text{var}(\xi^2) = 4\mu^2 \sigma^2 + 2\sigma^4$
高斯对数似然	$\ln p = -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_n (x[n] - s[n; \theta])^2$

13. 解题流程（拿到新问题按此走）

1. 写出 $p(\mathbf{x};\theta)$ → 取对数 → 求一阶导 $\partial \ln p / \partial \theta$

↓

2. 【先试】能否配成 $I(\theta) \cdot (g(\mathbf{x}) - \theta)$?

├ 能 → 同时读出:

├ • $I(\theta)$ = 提出的系数

├ • MVU 估计量 $\hat{\theta} = g(\mathbf{x})$

├ • 最小方差 = $1/I(\theta)$

├ 【收工】

└ 不能 → 3. 继续求二阶导, 取期望得 $I(\theta)$

(WGN 中的信号可直接套 (3.14) 跳过此步)

↓

4. 得到 CRLB, 作为性能基准使用

↓

5. 有效估计量不存在。若仍要找 MVU:

├ 第 5 章 RBLS (充分统计量)

├ 第 6 章 BLUE (限定线性)

├ 第 7 章 MLE (渐近有效, 大样本首选)

↓

6. 若关心的是 $\alpha = g(\theta)$: 套 (3.16) 乘 $(\partial g / \partial \theta)^2$

⚠ 非线性时注意无偏/有效性会丢失

14. 与后续章节的连接

章节	内容	与本部分的关系
3.7-3.8	向量参数 CRLB、Fisher 信息矩阵	标量结论的矩阵推广; "参数越多界越大"
3.9	WSS 高斯过程的渐近 CRLB (基于 PSD)	大数据记录下的实用形式
第 4 章	线性模型	CRLB 必定可达的一大类模型
第 5 章	充分统计量、RBLS 定理	CRLB 够不着时找 MVU 的第二条路
第 6 章	BLUE	限定线性, 牺牲最优性换可解性
第 7 章	MLE	渐近无偏、渐近有效 (渐近达到 CRLB) + 不变性 (呼应 3.6)
第 10 章起	贝叶斯方法	记号从 $p(\mathbf{x};\theta)$ 变为 $p(\mathbf{x} \theta)$ + 先验; 界变为贝叶斯 CRLB

附：一页速记

1. $\text{mse} = \text{var} + \text{bias}^2$ ，偏差平方相加无交叉项（正交分解）
2. 平均只压方差不压偏差 $\Rightarrow$ 先强制无偏，再最小化方差 $\Rightarrow$ MVU
3. 似然 = 把 PDF 反过来看，固定数据、变参数，给候选 θ 打分
4. 精度 $\leftarrow$ 似然的尖锐度 $\leftarrow$ 对数似然的曲率 $\leftarrow$ Fisher 信息 $I(\theta)$
5. $\ln$ 来自 $\partial p / \partial \theta = p \cdot \partial \ln p / \partial \theta$ ，是为了把导数变回期望形式
6. CRLB: $\text{var}(\hat{\theta}) \geq 1/I(\theta)$ ，只对无偏估计量成立
7. $I(\theta)$ 能提前算，因为期望把数据积分掉了——它是模型的属性，不是实验的属性
8. 可达 $\Leftrightarrow$ 对数似然恰为抛物线，顶点 $g(\mathbf{x})$ 就是 MVU 估计量，开口 $I(\theta)$ 就是精度
9. WGN 中：CRLB = 噪声功率 $\div$ 信号对参数的敏感度能量， s'' 被期望抹掉
10. 换参数：界乘 $(g')^2$ ，但最优性不跟着搬家